รายงานโครงงานคอมพิวเตอร์

การประยุกต์ใช้การเรียนรู้ของเครื่องเพื่อทำนายฤทธิ์ทางชีวภาพ และวิเคราะห์ความสัมพันธ์ระหว่างโครงสร้างกับฤทธิ์ ของสารยับยั้ง SARS-CoV-2 Main Protease แบบ In Silico

Machine Learning Application for In Silico Bioactivity Prediction and Structure–Activity Relationship Analysis of SARS-CoV-2 Main Protease Inhibitors

โดย

6633800639-0	นายรุ่งธรรม	ล้อมในเมือง
683380668-7	นางสาววรรณวิษา	เลาเลิศ

อาจารย์ที่ปรึกษาโครงงาน : อาจารย์ธนพล ตั้งชูพงศ์

รายงานฉบับนี้เป็นส่วนหนึ่งของการศึกษา

วิชา CP352101 วิทยาการข้อมูลขั้นแนะนำ

ภาคเรียนที่ 1 ปีการศึกษา 2569 สาขาวิชาวิทยาการคอมพิวเตอร์

วิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่น

บทคัดย่อ

กระบวนการค้นหาและพัฒนายาใหม่เผชิญข้อจำกัดด้านระยะเวลาและต้นทุนมหาศาล การทดสอบฤทธิ์ทางชีวภาพของสารเคมีในห้องปฏิบัติการจริงกับโปรตีนเป้าหมาย เช่น เอนไซม์ Main Protease (M^{pro} หรือ $3CL^{pro}$) ของเชื้อไวรัส SARS-CoV-2 มีขั้นตอนซับซ้อนและมีค่าใช้จ่ายสูง โครงงานนี้จึงพัฒนาแบบจำลองการเรียนรู้ของเครื่องเพื่อทำนายค่าความสามารถในการยับยั้งเอนไซม์ในรูป pIC_{50} แบบ In Silico

คณะผู้จัดทำรวบรวมข้อมูลจากฐานข้อมูล ChEMBL เป้าหมาย CHEMBL4523582 จำนวน 4,867 รายการ กรองเฉพาะ assay ที่วัด $3CL^{pro}$ เหลือ 2,889 รายการ และผ่านกระบวนการทำความสะอาด 13 ขั้นตอน ได้ชุดข้อมูลมาตรฐาน 2,198 โมเลกุลที่ไม่ซ้ำกัน สกัดคุณลักษณะแบบผสม (Hybrid Features) จำนวน 1,028 มิติ ประกอบด้วย Morgan Fingerprints (ECFP4 รัศมี 2 ขนาด 1,024 บิต) และ Lipinski Descriptors 4 ตัว จากนั้นเปรียบเทียบแบบจำลอง 4 ชนิด ได้แก่ Dummy Regressor, Random Forest, XGBoost และ Support Vector Regressor ผ่าน Scikit-learn Pipeline ที่ป้องกันการรั่วไหลของข้อมูล พร้อมทำ 5-Fold Cross-Validation และปรับจูนไฮเปอร์พารามิเตอร์

ผลการทดลองพบว่า XGBoost ให้ประสิทธิภาพสูงสุดบนชุดทดสอบ โดยมีค่า $R^2 = 0.7034$, RMSE = 0.5487, MAE = 0.3918 และ Spearman $\rho = 0.8415$ ซึ่งเหนือกว่าแบบจำลองพื้นฐานอย่างชัดเจน ($R^2 \approx 0.0000$) การทำนายร้อยละ 93.6 มีความคลาดเคลื่อนไม่เกิน 1 log unit เมื่อทดสอบด้วยการแบ่งข้อมูลตามโครงสร้างแกนกลาง (Scaffold Split) ค่า R^2 ลดลงเหลือ 0.5127 ซึ่งสะท้อนความสามารถทำนายที่แท้จริงเมื่อพบสารแกนโครงสร้างใหม่

การวิเคราะห์ด้วยเทคนิค SHAP พบว่าน้ำหนักโมเลกุลเป็นคุณลักษณะสำคัญที่สุด (Mean|SHAP| = 0.1165) และสามารถระบุโครงสร้างย่อย 2 มิติที่สัมพันธ์กับการเพิ่มและลดฤทธิ์ยับยั้งได้ 6 บิต โดยบิตที่ 301 พบในสารกลุ่ม active ร้อยละ 50.9 แต่พบในกลุ่ม inactive เพียงร้อยละ 13.1

ข้อค้นพบที่สำคัญคือ การทดสอบข้ามชุดข้อมูลกับสาร COVID-19 จากแหล่งอิสระ 90 ตัว ให้ค่า $R^2 = -1.72$ ซึ่งแย่กว่าการทำนายด้วยค่าเฉลี่ย สาเหตุมาจากร้อยละ 84.4 ของสารกลุ่มดังกล่าวอยู่นอกขอบเขตการใช้งานของแบบจำลอง (Applicability Domain) ผลนี้ชี้ว่าแบบจำลอง QSAR ที่มีค่า R^2 สูงบนชุดทดสอบภายในไม่ได้รับประกันความสามารถทำนายสารนอกปริภูมิเคมีเดิม

คำสำคัญ: การเรียนรู้ของเครื่อง, QSAR, SARS-CoV-2 Main Protease, pIC_{50}, Morgan Fingerprints, SHAP, Applicability Domain

Abstract

Drug discovery is constrained by substantial time and cost requirements. Experimental determination of compound bioactivity against protein targets such as the SARS-CoV-2 Main Protease (M^{pro}/$3CL^{pro}$) is laborious and expensive. This project develops machine learning models to predict enzyme inhibition potency (pIC_{50}) in silico.

Bioactivity data were retrieved from ChEMBL target `CHEMBL4523582`, yielding 4,867 IC_{50} records. Assay-level filtering for $3CL^{pro}$ retained 2,889 records, and a 13-step cleaning protocol produced a curated dataset of 2,198 unique molecules. Hybrid features comprising 1,024-bit Morgan fingerprints (ECFP4, radius 2) and four Lipinski descriptors (1,028 dimensions in total) were extracted. Four regressors — Dummy, Random Forest, XGBoost and Support Vector Regressor — were compared within a leakage-safe Scikit-learn Pipeline using 5-fold cross-validation and hyperparameter tuning.

XGBoost achieved the best held-out performance (R^2 = 0.7034, RMSE = 0.5487, MAE = 0.3918, Spearman ρ = 0.8415), substantially exceeding the baseline ($R^2 \approx 0.0000$); 93.6% of predictions fell within one log unit. Under a Bemis–Murcko scaffold split, R^2 decreased to 0.5127, providing a more realistic estimate of prospective performance.

SHAP analysis identified molecular weight as the most influential feature (Mean|SHAP| = 0.1165) and mapped six fingerprint bits to interpretable 2D substructures; bit 301 occurred in 50.9% of active compounds versus 13.1% of inactives.

Critically, external validation on 90 independent COVID-19 compounds yielded $R^2 = -1.72$, worse than mean prediction, because 84.4% of these compounds fell outside the model's applicability domain. This demonstrates that high internal test performance in QSAR does not guarantee generalisation beyond the training chemical space.

Keywords: Machine Learning, QSAR, SARS-CoV-2 Main Protease, pIC_{50}, Morgan Fingerprints, SHAP, Applicability Domain

กิตติกรรมประกาศ

รายงานฉบับนี้สำเร็จลุล่วงได้ด้วยความกรุณาจากอาจารย์ธนพล ตั้งชูพงศ์ อาจารย์ที่ปรึกษาโครงงาน ที่ให้คำแนะนำและข้อคิดเห็นอันเป็นประโยชน์ตลอดระยะเวลาการดำเนินงาน คณะผู้จัดทำขอขอบพระคุณเป็นอย่างสูงมา ณ ที่นี้

ขอขอบคุณสถาบัน European Bioinformatics Institute (EMBL-EBI) ที่เปิดให้เข้าถึงฐานข้อมูล ChEMBL โดยไม่มีค่าใช้จ่าย และขอขอบคุณผู้พัฒนาซอฟต์แวร์โอเพนซอร์ส RDKit, Scikit-learn, XGBoost และ SHAP ซึ่งเป็นเครื่องมือหลักที่ทำให้โครงงานนี้เป็นไปได้

คณะผู้จัดทำ
กันยายน 2569

สารบัญ

บทคัดย่อ i

Abstract ii

กิตติกรรมประกาศ iii

1 บทนำ 1

1.1 ความเป็นมาและความสำคัญของปัญหา 1

1.2 วัตถุประสงค์ของโครงงาน 2

1.3 ขอบเขตของโครงงาน 2

1.4 ข้อจำกัดของโครงงาน 3

1.5 ประโยชน์ที่คาดว่าจะได้รับ 3

1.6 นิยามศัพท์เฉพาะ 4

2 ทฤษฎีและงานวิจัยที่เกี่ยวข้อง 5

2.1 เอนไซม์เป้าหมายและค่าฤทธิ์ทางชีวภาพ 5

2.1.1 SARS-CoV-2 Main Protease 5

2.1.2 ค่า IC_{50} และการแปลงเป็น pIC_{50} 5

2.2 การแทนรหัสโครงสร้างเคมีและคุณลักษณะโมเลกุล 6

2.2.1 SMILES 6

2.2.2 Morgan Fingerprints (ECFP4) 6

2.2.3 กฎของลิพินสกีและ Lipinski Descriptors 7

2.2.4 คุณลักษณะแบบผสม (Hybrid Features) 7

2.3 อัลกอริทึมการเรียนรู้ของเครื่อง 7

2.3.1 Dummy Regressor 7

2.3.2 Random Forest Regressor 8

2.3.3 XGBoost Regressor 8

2.3.4 Support Vector Regressor (SVR) 8

2.4 การป้องกันการรั่วไหลของข้อมูล 9

2.4.1 นิยามและประเภทของ Data Leakage 9
2.4.2 การแก้ปัญหาด้วย Pipeline และ ColumnTransformer 9
2.5 การประเมินประสิทธิภาพแบบจำลอง 10
2.5.1 ตัวชี้วัด 10
2.5.2 K-Fold Cross-Validation 10
2.5.3 Scaffold Split 10
2.5.4 Applicability Domain 11
2.6 การอธิบายแบบจำลองด้วย SHAP 11
2.7 งานวิจัยที่เกี่ยวข้อง 11

3 วิธีดำเนินการวิจัย **13**
3.1 กรอบการดำเนินงาน 13
3.2 เครื่องมือที่ใช้ 14
3.2.1 ฮาร์ดแวร์ 14
3.2.2 ซอฟต์แวร์ 14
3.3 การตรวจสอบชุดข้อมูลที่ได้รับมอบ 15
3.4 การรวบรวมข้อมูล 16
3.4.1 การเลือกเป้าหมาย 16
3.4.2 การกรอง assay เฉพาะ $3CL^{pro}$ 16
3.4.3 การเตรียมชุด DDH 16
3.5 การทำความสะอาดข้อมูล 16
3.6 การสกัดคุณลักษณะ 18
3.7 การสำรวจข้อมูล 18
3.8 การแบ่งข้อมูล 19
3.8.1 Random Split 19
3.8.2 Scaffold Split 19
3.9 การสร้าง Pipeline ป้องกันการรั่วไหล 19
3.10 การออกแบบการทดลอง 20
3.11 การปรับจูนไฮเปอร์พารามิเตอร์ 20
3.12 การประเมินบนชุดทดสอบ 21
3.13 การวิเคราะห์ SHAP และ SAR 22

3.14 การทดสอบข้ามชุดข้อมูลและ Applicability Domain 22

4 ผลการดำเนินงาน **23**

4.1 ผลการรวบรวมและกรองข้อมูล 23

4.2 ผลการทำความสะอาดข้อมูล 24

4.3 ผลการสำรวจข้อมูล 25

4.4 ผลการทำ Cross-Validation 29

4.5 ผลการปรับจูนและประเมินบนชุดทดสอบ 31

4.6 การวิเคราะห์ค่าคลาดเคลื่อน 32

4.7 ผลการวิเคราะห์ SHAP และ SAR 33

4.8 ผลการทดสอบข้ามชุดข้อมูล 39

5 สรุปผล อภิปรายผล และข้อเสนอแนะ **42**

5.1 สรุปผลการดำเนินงาน 42

5.2 อภิปรายผลตามวัตถุประสงค์ 43

5.2.1 อภิปรายวัตถุประสงค์ที่ 1 43

5.2.2 อภิปรายวัตถุประสงค์ที่ 2 43

5.2.3 อภิปรายวัตถุประสงค์ที่ 3 44

5.3 ข้อค้นพบสำคัญที่นอกเหนือจากวัตถุประสงค์ 44

5.3.1 ความล้มเหลวของการทดสอบข้ามชุดข้อมูล 44

5.3.2 ผลกระทบของความไม่สมดุลของข้อมูล 45

5.3.3 ข้อจำกัดของ Morgan Fingerprints กับสเตอริโอเคมี 45

5.4 ข้อจำกัดของการศึกษา 45

5.5 ข้อเสนอแนะ 46

5.5.1 ข้อเสนอแนะสำหรับการนำผลไปใช้ 46

5.5.2 ข้อเสนอแนะสำหรับการพัฒนาต่อยอด 46

5.5.3 ข้อเสนอแนะเชิงระเบียบวิธีสำหรับงาน QSAR 47

บรรณานุกรม **48**

A โครงสร้างไฟล์และโค้ดโปรแกรม **50**

A.1 โครงสร้างโปรเจกต์ 50

A.2 ลำดับการรันโปรแกรม 50

A.3 โค้ดสำคัญ: Pipeline ป้องกัน Data Leakage 51
A.4 โค้ดสำคัญ: Scaffold Split 51
A.5 โค้ดสำคัญ: การสกัดคุณลักษณะแบบผสม 51

B รายการไฟล์ผลลัพธ์ 53

B.1 รายการภาพประกอบ 53
B.2 รายการตารางผลลัพธ์ดิบ 54

สารบัญตาราง

1.1 นิยามศัพท์เฉพาะที่ใช้ในรายงาน 4

2.1 กฎห้าประการของลิพินสกีและความหมายของแต่ละ Descriptor 7
2.2 ตัวชี้วัดประสิทธิภาพที่ใช้ในโครงงาน 10

3.1 ระยะการดำเนินงานทั้ง 9 ระยะ 13
3.2 ซอฟต์แวร์และไลบรารีที่ใช้ 14
3.3 ผลการตรวจสอบชุดข้อมูลที่ได้รับมอบ 15
3.4 ขั้นตอนการทำความสะอาดข้อมูล 13 ขั้น 17
3.5 โครงสร้างคอลัมน์ของชุดข้อมูลมาตรฐาน `clean_bioactivity_master.csv` . 18
3.6 การออกแบบการทดลอง E1–E6 20
3.7 ค่าไฮเปอร์พารามิเตอร์ที่ใช้ค้นหา 21
3.8 เกณฑ์ตีความค่า R^2 ที่กำหนดไว้ล่วงหน้า 21

4.1 ผลการกรอง assay 23
4.2 ผลการทำความสะอาดข้อมูลทีละขั้น 24
4.3 สรุปคุณลักษณะชุดข้อมูล 25
4.4 โครงสร้างแกนกลาง Murcko 10 อันดับแรก 28
4.5 การเปรียบเทียบ Lipinski Descriptors ด้วย Mann-Whitney U (active เทียบ inactive) 28
4.6 ผล 5-Fold Cross-Validation บนชุดฝึก Random Split (E1) 29
4.7 ผล 5-Fold Cross-Validation บนชุดฝึก Scaffold Split (E2) 29
4.8 ผลการศึกษา Ablation 30
4.9 ผลการพิสูจน์ Data Leakage 30
4.10 ไฮเปอร์พารามิเตอร์ที่ดีที่สุด (Random Split) 31
4.11 ผลการประเมินบนชุดทดสอบ Random Split ($n = 550$) 31
4.12 ผลการประเมินบนชุดทดสอบ Scaffold Split ($n = 549$) 31
4.13 การวิเคราะห์ค่าคลาดเคลื่อนแยกตามกลุ่มฤทธิ์ 33
4.14 ค่าความสำคัญของคุณลักษณะ 20 อันดับแรก 34

4.15 ตารางวิเคราะห์ SAR ของโครงสร้างย่อยที่สำคัญ 37
4.16 ผลการทดสอบข้ามชุดข้อมูลกับ DDH COVID-19 39
4.17 ผลการวิเคราะห์ Applicability Domain 39
4.18 ผลการทำนายสาร BLINDED จำนวน 10 ตัว 41

5.1 สรุปการบรรลุวัตถุประสงค์ 43

B.1 รายการภาพประกอบผลการดำเนินงาน 53
B.2 รายการไฟล์ตารางผลลัพธ์ 54

สารบัญภาพ

4.1 การแจกแจงความถี่ของค่า pIC_{50} ในชุดข้อมูลหลัก 26
4.2 ปริภูมิเคมีระหว่างน้ำหนักโมเลกุลกับค่า LogP แยกตามกลุ่มฤทธิ์ 26
4.3 การเปรียบเทียบ Lipinski Descriptors ตามกลุ่มฤทธิ์ 27
4.4 การเปรียบเทียบปริภูมิเคมีของชุดข้อมูลสามชุด 27
4.5 การเปรียบเทียบประสิทธิภาพแบบจำลองระหว่าง Cross-Validation กับชุดทดสอบ 32
4.6 กราฟค่าทำนายเทียบค่าจริง (ซ้าย) และกราฟค่าคลาดเคลื่อน (ขวา) 32
4.7 การแจกแจงค่าคลาดเคลื่อน 33
4.8 ค่าความสำคัญของคุณลักษณะ 20 อันดับแรกโดย Mean|SHAP| 35
4.9 SHAP Beeswarm Plot แสดงทิศทางอิทธิพลของแต่ละคุณลักษณะ 36
4.10 SHAP Dependence Plot ของค่า LogP 37
4.11 โครงสร้างย่อย 2 มิติของบิตสำคัญทั้ง 6 บิตที่ได้จากการจับคู่ย้อนกลับ 38
4.12 ผลการทดสอบข้ามชุดข้อมูล (ซ้าย) และการเลื่อนของการกระจายตัวแปรตาม (ขวา) 40
4.13 การวิเคราะห์ Applicability Domain ด้วยค่าความคล้ายคลึง Tanimoto 40

บทที่ 1

บทนำ

1.1 ความเป็นมาและความสำคัญของปัญหา

กระบวนการค้นหาและพัฒนายาใหม่ (Drug Discovery) ในปัจจุบันต้องเผชิญกับข้อจำกัดด้านระยะเวลาและต้นทุนมหาศาล การนำยาหนึ่งชนิดออกสู่ตลาดใช้เวลาเฉลี่ย 10–15 ปี และมีค่าใช้จ่ายหลายพันล้านบาท ขั้นตอนที่เป็นคอขวดสำคัญคือการคัดกรองสารเคมีจำนวนมหาศาลเพื่อหาสารที่มีศักยภาพ ซึ่งการทดสอบฤทธิ์ทางชีวภาพในห้องปฏิบัติการจริง (Wet Lab Experiment) กับโปรตีนเป้าหมายมีขั้นตอนที่ซับซ้อนและมีค่าใช้จ่ายสูง

เชื้อไวรัส SARS-CoV-2 ซึ่งเป็นสาเหตุของโรค COVID-19 มีเอนไซม์ Main Protease (M^{pro} หรือเรียกอีกชื่อว่า $3CL^{pro}$) เป็นเอนไซม์ชนิดซิสเตอีนโปรตีเอส (Cysteine Protease) ที่มีบทบาทสำคัญยิ่งในวงจรชีวิตของไวรัส เอนไซม์นี้ทำหน้าที่ตัดสายพอลิโปรตีนที่ไวรัสสร้างขึ้นให้กลายเป็นโปรตีนย่อยที่ทำงานได้ (Non-structural Proteins) ซึ่งจำเป็นต่อการเพิ่มจำนวนของไวรัส การยับยั้งการทำงานของ M^{pro} จึงสามารถหยุดยั้งกระบวนการแบ่งตัวของไวรัสได้โดยตรง และเนื่องจากมนุษย์ไม่มีเอนไซม์ที่มีความคล้ายคลึงกับ M^{pro} ทำให้เอนไซม์นี้เป็นเป้าหมายยาที่น่าสนใจอย่างยิ่ง เพราะมีโอกาสเกิดผลข้างเคียงต่อเซลล์มนุษย์ต่ำ

การพัฒนาวิธีการคำนวณทางคอมพิวเตอร์แบบจำลองในคอมพิวเตอร์ (In Silico) จึงเข้ามามีบทบาทสำคัญในการคัดกรองและประเมินประสิทธิภาพสารเคมีเบื้องต้นก่อนนำไปทดสอบจริง แนวทางหนึ่งที่ได้รับการยอมรับคือการศึกษาความสัมพันธ์เชิงปริมาณระหว่างโครงสร้างทางเคมีกับการออกฤทธิ์ทางชีวภาพ (Quantitative Structure-Activity Relationship: QSAR) ซึ่งในทางวิทยาการข้อมูลถือเป็นโจทย์ปัญหาประเภทการถดถอย (Regression Problem) โดยมีเป้าหมายเพื่อทำนายค่าความสามารถในการยับยั้งเอนไซม์ ซึ่งวัดจากค่าความเข้มข้นที่ยับยั้งการทำงานได้ครึ่งหนึ่ง (Half Maximal Inhibitory Concentration: IC_{50}) ในหน่วยนาโนโมลาร์ (nM) และแปลงให้อยู่ในรูปตัวแปรต่อเนื่องที่มีการกระจายตัวแบบสมมาตร (pIC_{50})

การทำนายฤทธิ์สารเคมีอย่างมีประสิทธิภาพจำเป็นต้องอาศัยการสกัดคุณลักษณะ (Feature Extraction) จากโครงสร้างโมเลกุลในรูปแบบ SMILES ประกอบด้วยคุณลักษณะเชิงโครงสร้างย่อย 2 มิติ (Morgan Fingerprints หรือ ECFP4) และคุณสมบัติทางกายภาพเคมีตามกฎของลิพินสกี (Lipinski's Descriptors) ได้แก่ น้ำหนักโมเลกุล (MW) ค่าสัมประสิทธิ์การละลาย (LogP) จำนวนอะตอมผู้ให้ไฮโดรเจน (HBD) และจำนวนอะตอมผู้รับไฮโดรเจน (HBA) มาประกอบเป็นชุดคุณลักษณะแบบผสม (Hybrid Features)

นอกจากนี้ ปัญหาสำคัญที่พบบ่อยในงาน QSAR คือการรั่วไหลของข้อมูล (Data Leakage)

ระหว่างการปรับสเกลข้อมูลกับกระบวนการตรวจสอบความถูกต้องข้ามกลุ่ม (Cross-Validation) ซึ่งทำให้ผลลัพธ์ที่รายงานสูงเกินจริง โครงงานนี้จึงประยุกต์ใช้ Scikit-learn Pipeline ในการผนวกขั้นตอนการปรับมาตรฐานข้อมูลเข้ากับแบบจำลอง และใช้เทคนิคปัญญาประดิษฐ์ที่อธิบายได้ (Explainable AI: SHAP) เพื่อวิเคราะห์ความสำคัญของคุณลักษณะโครงสร้าง พร้อมทำการจับคู่ย้อนกลับ (Bit Mapping) เป็นภาพโครงสร้างย่อย 2 มิติ เพื่ออธิบายความสัมพันธ์ระหว่างโครงสร้างโมเลกุลกับฤทธิ์การยับยั้งเอนไซม์ได้อย่างโปร่งใสและตรวจสอบได้

1.2 วัตถุประสงค์ของโครงงาน

1. เพื่อพัฒนาและเปรียบเทียบประสิทธิภาพของแบบจำลองการเรียนรู้ของเครื่อง (Machine Learning) ในการทำนายค่าฤทธิ์การยับยั้งเอนไซม์ SARS-CoV-2 Main Protease (pIC_{50}) แบบ In Silico

2. เพื่อสร้างกระบวนการเตรียมและสกัดคุณลักษณะโมเลกุลแบบผสม (Hybrid Features) จาก Morgan Fingerprints และ Lipinski Descriptors ผ่าน Scikit-learn Pipeline ที่ป้องกันการรั่วไหลของข้อมูล (Data Leakage)

3. เพื่อวิเคราะห์และอธิบายความสัมพันธ์ระหว่างคุณลักษณะทางโครงสร้างกับฤทธิ์ทางชีวภาพ (SAR Analysis) โดยใช้เทคนิค Explainable AI (SHAP) ร่วมกับการสกัดภาพโครงสร้างโมเลกุลย่อย 2 มิติ

1.3 ขอบเขตของโครงงาน

1. มุ่งเน้นศึกษาเฉพาะสารยับยั้งเอนไซม์ Main Protease (M^{pro}) ของเชื้อไวรัส SARS-CoV-2 โดยใช้ข้อมูลจากฐานข้อมูล ChEMBL

2. ใช้ค่า IC_{50} ที่มีหน่วยการวัดเป็นนาโนโมลาร์ (nM) เท่านั้น และแปลงเป็น pIC_{50} สำหรับการสร้างแบบจำลองประเภทการถดถอย

3. สกัดคุณลักษณะโมเลกุลแบบ 2 มิติ ได้แก่ Morgan Fingerprints ขนาด 1,024 บิต และ Lipinski Descriptors 4 ค่า รวมเป็น 1,028 คุณลักษณะ

4. เปรียบเทียบแบบจำลองการเรียนรู้ของเครื่อง 4 ชนิด ได้แก่ Dummy Regressor (Baseline), Random Forest, XGBoost และ Support Vector Regressor (SVR)

5. ประเมินประสิทธิภาพด้วยตัวชี้วัด R^2, RMSE และ MAE ร่วมกับการทำ 5-Fold Cross Validation

1.4 ข้อจำกัดของโครงงาน

1. การศึกษานี้เป็นการจำลองและวิเคราะห์ทางคอมพิวเตอร์ (In Silico) เท่านั้น ไม่ได้มีการทดสอบยืนยันในห้องปฏิบัติการจริง (In Vitro Validation)
2. การวิเคราะห์ SAR ผ่าน SHAP เป็นการระบุ **ความสัมพันธ์เชิงสถิติ (Statistical Association)** ระหว่างชิ้นส่วนโมเลกุลกับการทำนายของแบบจำลอง ไม่สามารถอ้างเป็นกลไกการจับทางชีวภาพเชิงสาเหตุระดับอะตอม 3 มิติ (Causal Mechanism) ได้
3. ไม่ครอบคลุมการคำนวณพลศาสตร์โมเลกุล 3 มิติ (Molecular Dynamics) หรือการจำลองการจับตัวของลิแกนด์กับโปรตีน (Molecular Docking)

1.5 ประโยชน์ที่คาดว่าจะได้รับ

1. ได้แบบจำลองการเรียนรู้ของเครื่องที่มีความแม่นยำและปราศจากปัญหา Data Leakage สำหรับทำนายค่าฤทธิ์การยับยั้งเอนไซม์ SARS-CoV-2 Main Protease (pIC_{50}) เบื้องต้นได้อย่างรวดเร็ว
2. ทราบถึงคุณลักษณะทางโครงสร้างย่อย 2 มิติ (Substructures) และคุณสมบัติทางเคมีกายภาพที่มีความสัมพันธ์ต่อระดับการออกฤทธิ์ยับยั้งเอนไซม์ ซึ่งสามารถใช้เป็นแนวทางชี้นำสำหรับนักเคมียาในการออกแบบโมเลกุลตัวยาใหม่
3. ได้ชุดข้อมูลโครงสร้างโมเลกุลมาตรฐานที่ผ่านการทำความสะอาดและสกัดคุณลักษณะแล้ว (`clean_bioactivity_master.csv`) เพื่อนำไปต่อยอดในงานวิจัยด้านเคมีสารสนเทศ (Cheminformatics) และการพัฒนาเว็บแอปพลิเคชันคัดกรองตัวยาในอนาคต

1.6 นิยามศัพท์เฉพาะ

ตารางที่ 1.1 นิยามศัพท์เฉพาะที่ใช้ในรายงาน

ศัพท์	ความหมาย
M^{pro} / $3CL^{pro}$	Main Protease หรือ 3C-like Protease เอนไซม์ซิสเตอีนโปรตีเอสของ SARS-CoV-2 ที่ทำหน้าที่ตัดสายพอลิโปรตีนของไวรัส
IC_{50}	ความเข้มข้นของสารที่ยับยั้งการทำงานของเอนไซม์ได้ร้อยละ 50 ค่ายิ่งต่ำแสดงว่าสารยิ่งมีฤทธิ์แรง
pIC_{50}	ค่าลอการิทึมติดลบของ IC_{50} ในหน่วยโมลาร์ คำนวณจาก $9 - \log_{10}(IC_{50}[\text{nM}])$ ค่ายิ่งสูงแสดงว่าสารยิ่งมีฤทธิ์แรง
SMILES	Simplified Molecular Input Line Entry System ระบบแทนโครงสร้างทางเคมีด้วยสายอักขระ
Morgan Fingerprints (ECFP4)	เวกเตอร์บิตที่เข้ารหัสโครงสร้างย่อย 2 มิติของโมเลกุล โดยพิจารณาสภาพแวดล้อมรอบอะตอมภายในรัศมีที่กำหนด
Lipinski Descriptors	คุณสมบัติทางเคมีกายภาพ 4 ค่า (MW, LogP, HBD, HBA) ที่บ่งบอกความเป็นไปได้ในการพัฒนาเป็นยารับประทาน
QSAR	Quantitative Structure-Activity Relationship การศึกษาความสัมพันธ์เชิงปริมาณระหว่างโครงสร้างเคมีกับการออกฤทธิ์
Data Leakage	การรั่วไหลของสารสนเทศจากชุดข้อมูลทดสอบเข้าสู่กระบวนการฝึกแบบจำลอง ทำให้ผลประเมินสูงเกินจริง
SHAP	SHapley Additive exPlanations วิธีอธิบายการตัดสินใจของแบบจำลองตามทฤษฎีเกม
Scaffold Split	การแบ่งข้อมูลโดยจัดโมเลกุลที่มีโครงสร้างแกนกลางเดียวกันไว้ฝั่งเดียวกัน เพื่อทดสอบความสามารถทำนายสารแกนโครงสร้างใหม่
Applicability Domain	ขอบเขตปริภูมิเคมีที่แบบจำลองมีความน่าเชื่อถือในการทำนาย
Activity Cliff	ปรากฏการณ์ที่โมเลกุลมีโครงสร้างคล้ายกันมากแต่มีฤทธิ์ทางชีวภาพแตกต่างกันอย่างมาก

บทที่ 2

ทฤษฎีและงานวิจัยที่เกี่ยวข้อง

2.1 เอนไซม์เป้าหมายและค่าฤทธิ์ทางชีวภาพ

2.1.1 SARS-CoV-2 Main Protease

เอนไซม์ SARS-CoV-2 Main Protease (M^{pro}) เป็นเอนไซม์ชนิดซิสเตอีนโปรตีเอสที่เข้ารหัสอยู่ในบริเวณ nsp5 ของ Replicase Polyprotein 1ab เอนไซม์นี้ทำงานในรูปไดเมอร์ (Dimer) และมีตำแหน่งเร่งปฏิกิริยา (Catalytic Dyad) ประกอบด้วยกรดอะมิโนฮิสทิดีนที่ตำแหน่ง 41 และซิสเตอีนที่ตำแหน่ง 145

หน้าที่หลักของ M^{pro} คือการตัดสายพอลิโปรตีน pp1a และ pp1ab ที่ไวรัสสร้างขึ้นให้กลายเป็นโปรตีนย่อยที่ทำงานได้ โดย M^{pro} รับผิดชอบการตัดอย่างน้อย 11 ตำแหน่ง การยับยั้งเอนไซม์นี้จึงหยุดกระบวนการเพิ่มจำนวนของไวรัสได้โดยตรง Jin และคณะ (2020) ได้รายงานโครงสร้างผลึกของ M^{pro} พร้อมการค้นพบสารยับยั้ง ซึ่งเป็นงานพื้นฐานสำคัญที่กระตุ้นการวิจัยสารยับยั้ง M^{pro} อย่างกว้างขวาง

ความสำคัญเชิงเภสัชวิทยาของ M^{pro} อยู่ที่การที่มนุษย์ไม่มีเอนไซม์ที่มีความคล้ายคลึงเชิงโครงสร้างและหน้าที่ ทำให้สารยับยั้งที่ออกแบบมาจำเพาะต่อ M^{pro} มีโอกาสเกิดพิษต่อเซลล์เจ้าบ้านต่ำ ตัวอย่างยาที่พัฒนาสำเร็จบนหลักการนี้คือ Nirmatrelvir ซึ่งเป็นองค์ประกอบหลักของยา Paxlovid

2.1.2 ค่า IC_{50} และการแปลงเป็น pIC_{50}

ค่า IC_{50} (Half Maximal Inhibitory Concentration) เป็นตัวชี้วัดความเข้มข้นของสารที่ใช้ยับยั้งการทำงานของเอนไซม์ได้ร้อยละ 50 ข้อมูลในฐานข้อมูล ChEMBL ถูกจัดเก็บในหน่วยนาโนโมลาร์ (nM) และมีการกระจายตัวแบบเบ้ขวาอย่างรุนแรง (Right-skewed) เนื่องจากค่าครอบคลุมหลายลำดับขนาด

การแปลงเป็นค่า pIC_{50} ช่วยลดความเบ้ของข้อมูลและทำให้ตัวแปรตามมีการกระจายตัวใกล้เคียงปกติ ซึ่งเหมาะสมกับการสร้างแบบจำลองการถดถอย โดยมีความสัมพันธ์ทางคณิตศาสตร์ดังสมการที่ 2.1

$$pIC_{50} = -\log_{10}(IC_{50}[\mathrm{M}]) = 9 - \log_{10}(IC_{50}[\mathrm{nM}]) \tag{2.1}$$

ตัวอย่างเช่น สารที่มี IC_{50} = 100 nM จะมี $pIC_{50} = 9 - \log_{10}(100) = 9 - 2 = 7.0$ ค่า pIC_{50} ที่สูงกว่าหมายถึงสารมีฤทธิ์แรงกว่า

ข้อควรระวังเรื่องหน่วย

ในบางแหล่งข้อมูลค่า pIC_{50} ถูกคำนวณบนฐานหน่วยไมโครโมลาร์ (μM) ซึ่งจะมีความสัมพันธ์ $pIC_{50}(\mu\text{M basis}) = pIC_{50}(\text{มาตรฐาน}) - 6$ การนำข้อมูลจากต่างแหล่งมารวมกันจึงต้องตรวจสอบหน่วยฐานให้ตรงกันก่อนเสมอ

2.2 การแทนรหัสโครงสร้างเคมีและคุณลักษณะโมเลกุล

2.2.1 SMILES

SMILES (Simplified Molecular Input Line Entry System) เป็นระบบแทนโครงสร้างทางเคมีด้วยสายอักขระ ทำให้สามารถจัดเก็บและประมวลผลโครงสร้างโมเลกุลด้วยคอมพิวเตอร์ได้อย่างมีประสิทธิภาพ โมเลกุลเดียวกันอาจเขียนเป็น SMILES ได้หลายรูปแบบ จึงจำเป็นต้องแปลงให้อยู่ในรูปมาตรฐาน (Canonical SMILES) ก่อนการเปรียบเทียบหรือยุบข้อมูลซ้ำ

2.2.2 Morgan Fingerprints (ECFP4)

Morgan Fingerprints เป็นอัลกอริทึมเข้ารหัสโครงสร้าง 2 มิติที่พัฒนาโดย Rogers และ Hahn (2010) หลักการทำงานคือการพิจารณาสภาพแวดล้อมรอบอะตอมแต่ละตัวภายในรัศมีที่กำหนด แล้วแปลงเป็นเวกเตอร์บิตความยาวคงที่

เมื่อกำหนดรัศมี $r = 2$ อัลกอริทึมจะพิจารณาอะตอมข้างเคียงที่อยู่ห่างออกไปไม่เกิน 2 พันธะ ซึ่งเทียบเท่ากับเส้นผ่านศูนย์กลาง 4 พันธะ จึงเรียกว่า ECFP4 (Extended-Connectivity Fingerprint, diameter 4) ผลลัพธ์คือเวกเตอร์บิตขนาด 1,024 บิต โดยแต่ละบิตมีค่าเป็น 0 หรือ 1 บ่งบอกการมีอยู่หรือไม่มีของโครงสร้างย่อยแบบใดแบบหนึ่ง

ข้อได้เปรียบสำคัญของ Morgan Fingerprints คือความสามารถในการจับคู่ย้อนกลับ (Bit Mapping) กล่าวคือ เมื่อทราบว่าบิตใดมีความสำคัญ สามารถย้อนกลับไปวาดภาพโครงสร้างย่อยที่บิตนั้นเป็นตัวแทนได้ ทำให้ผลการวิเคราะห์สามารถตีความเชิงเคมีได้

ข้อจำกัด

Morgan Fingerprints ในการตั้งค่าปกติไม่บันทึกข้อมูลสเตอริโอเคมี (Stereochemistry) ทำให้สเตอริโอไอโซเมอร์ที่มีโครงสร้างเชิงเส้นเหมือนกันแต่มีการจัดเรียงในสามมิติต่างกันได้เวกเตอร์บิตที่เหมือนกันทุกประการ ข้อจำกัดนี้จะปรากฏผลจริงในบทที่ 5

2.2.3 กฎของลิพินสกีและ Lipinski Descriptors

Lipinski และคณะ (2001) เสนอกฎห้าประการ (Rule of Five) สำหรับประเมินความเป็นไปได้ที่สารจะพัฒนาเป็นยารับประทาน โดยสารที่มีคุณสมบัติเป็นยาที่ดีมักมีลักษณะดังตารางที่ 2.1

ตารางที่ 2.1 กฎห้าประการของลิพินสกีและความหมายของแต่ละ Descriptor

Descriptor	เกณฑ์	ความหมาย
MW (Molecular Weight)	≤ 500 Da	น้ำหนักโมเลกุล
LogP	≤ 5	ค่าสัมประสิทธิ์การแบ่งน้ำ–ออกทานอล บ่งบอกความชอบไขมัน
HBD (H-Bond Donors)	≤ 5	จำนวนอะตอมผู้ให้พันธะไฮโดรเจน
HBA (H-Bond Acceptors)	≤ 10	จำนวนอะตอมผู้รับพันธะไฮโดรเจน

คุณลักษณะเหล่านี้เป็นค่าตัวเลขต่อเนื่องที่มีสเกลแตกต่างกันมาก เช่น MW อยู่ในหลักร้อย ขณะที่ HBD อยู่ในหลักหน่วย จึงจำเป็นต้องปรับมาตรฐานก่อนใช้กับแบบจำลองที่ไวต่อสเกล เช่น SVR

2.2.4 คุณลักษณะแบบผสม (Hybrid Features)

การรวม Morgan Fingerprints ซึ่งเป็นข้อมูลไบนารีเชิงโครงสร้าง เข้ากับ Lipinski Descriptors ซึ่งเป็นข้อมูลตัวเลขต่อเนื่องเชิงคุณสมบัติ ทำให้ได้ชุดคุณลักษณะที่ครอบคลุมทั้งมิติโครงสร้างเฉพาะและมิติคุณสมบัติภาพรวมของโมเลกุล รวมเป็น $1{,}024 + 4 = 1{,}028$ คุณลักษณะ

ความท้าทายของการรวมข้อมูลสองประเภทนี้คือ ข้อมูลไบนารีไม่ควรถูกปรับมาตรฐานเพราะมีค่า 0/1 อยู่แล้ว ขณะที่ข้อมูลตัวเลขต่อเนื่องจำเป็นต้องปรับ จึงต้องใช้กลไก `ColumnTransformer` เพื่อจัดการคอลัมน์แต่ละกลุ่มแยกจากกัน

2.3 อัลกอริทึมการเรียนรู้ของเครื่อง

2.3.1 Dummy Regressor

แบบจำลองพื้นฐานที่ทำนายผลลัพธ์เป็นค่าเฉลี่ยของชุดข้อมูลฝึกเสมอ โดยไม่พิจารณาคุณลักษณะใด ๆ ใช้เป็นเกณฑ์มาตรฐานเปรียบเทียบขั้นต่ำ (Baseline Benchmark) หากแบบจำลองที่ซับซ้อนกว่าไม่สามารถทำได้ดีกว่า Dummy Regressor แสดงว่าคุณลักษณะที่ใช้ไม่มี

สารสนเทศเพียงพอ หรือกระบวนการสร้างแบบจำลองมีข้อผิดพลาด ในทางทฤษฎี Dummy Regressor จะให้ค่า R^2 ประมาณ 0 บนชุดทดสอบ และอาจติดลบเล็กน้อยหากค่าเฉลี่ยของชุดฝึกต่างจากชุดทดสอบ

2.3.2 Random Forest Regressor

Random Forest เป็นแบบจำลองรวมกลุ่ม (Ensemble Learning) ชนิด Bagging ที่พัฒนาโดย Breiman (2001) หลักการคือการสร้างต้นไม้ตัดสินใจจำนวนมากจากตัวอย่างที่สุ่มเลือกแบบมีการแทนที่ (Bootstrap Sampling) และในแต่ละโหนดจะพิจารณาเพียงคุณลักษณะย่อยที่สุ่มเลือกมาแล้วนำผลทำนายของทุกต้นมาเฉลี่ยกัน

การรวมผลจากต้นไม้หลายต้นช่วยลดความแปรปรวน (Variance) และลดปัญหาการเรียนรู้เกิน (Overfitting) ได้อย่างมีประสิทธิภาพ นอกจากนี้ค่าเบี่ยงเบนมาตรฐานของการทำนายจากต้นไม้แต่ละต้นยังสามารถใช้เป็นตัวแทนความไม่แน่นอนของการทำนายได้

2.3.3 XGBoost Regressor

XGBoost (Extreme Gradient Boosting) พัฒนาโดย Chen และ Guestrin (2016) เป็นอัลกอริทึม Boosting ที่สร้างต้นไม้แบบต่อเนื่อง โดยต้นไม้แต่ละต้นจะเรียนรู้เพื่อแก้ไขความคลาดเคลื่อนตกค้าง (Residuals) ของต้นไม้ก่อนหน้า ผ่านการปรับลดด้วยวิธี Gradient Descent

XGBoost มีกลไกการปรับให้เป็นปกติ (Regularization) ทั้งแบบ L1 และ L2 ในฟังก์ชันวัตถุประสงค์ ทำให้ควบคุมความซับซ้อนของแบบจำลองได้ดี และมีการปรับแต่งเชิงวิศวกรรมที่ทำให้ประมวลผลได้รวดเร็ว จึงเป็นที่นิยมอย่างสูงในงานข้อมูลตาราง

2.3.4 Support Vector Regressor (SVR)

SVR เป็นอัลกอริทึมที่หาไฮเปอร์เพลนที่เหมาะสมที่สุดภายในขอบเขตความคลาดเคลื่อน ε (Epsilon-insensitive tube) โดยจุดข้อมูลที่อยู่ภายในขอบเขตนี้จะไม่ถูกนับเป็นความคลาดเคลื่อน การใช้ฟังก์ชันเคอร์เนลแบบ RBF (Radial Basis Function) ทำให้ SVR สามารถจับความสัมพันธ์ที่ไม่เป็นเชิงเส้นได้

SVR มีความไวต่อสเกลของข้อมูลอย่างมาก เนื่องจากการคำนวณระยะทางในฟังก์ชันเคอร์เนล จึงจำเป็นต้องปรับมาตรฐานคุณลักษณะเชิงตัวเลขก่อนใช้งาน

2.4 การป้องกันการรั่วไหลของข้อมูล

2.4.1 นิยามและประเภทของ Data Leakage

Data Leakage คือการที่สารสนเทศจากชุดข้อมูลทดสอบรั่วไหลเข้าสู่กระบวนการฝึกแบบจำลอง ทำให้ผลการประเมินสูงเกินความเป็นจริง ในบริบทของงาน QSAR มี Data Leakage ที่พบบ่อยสองรูปแบบ

รูปแบบที่ 1: Preprocessing Leakage เกิดจากการคำนวณค่าสถิติสำหรับการปรับมาตรฐาน เช่น ค่าเฉลี่ยและส่วนเบี่ยงเบนมาตรฐาน จากข้อมูลทั้งชุดก่อนแบ่ง Train/Test ทำให้ค่าสถิติของชุดทดสอบมีอิทธิพลต่อการแปลงข้อมูลฝึก

รูปแบบที่ 2: Feature Selection Leakage เกิดจากการคัดเลือกคุณลักษณะโดยพิจารณาความสัมพันธ์กับตัวแปรตามบนข้อมูลทั้งชุดก่อนแบ่งข้อมูล ทำให้คุณลักษณะที่ถูกเลือกมีความรู้เกี่ยวกับชุดทดสอบติดมาด้วย รูปแบบนี้มักส่งผลรุนแรงกว่ารูปแบบแรก โดยเฉพาะเมื่อจำนวนคุณลักษณะตั้งต้นมีมาก

2.4.2 การแก้ปัญหาด้วย Pipeline และ ColumnTransformer

Scikit-learn Pipeline เป็นกลไกที่ผนวกขั้นตอนการแปลงข้อมูลเข้ากับแบบจำลองให้เป็นวัตถุเดียว เมื่อเรียกใช้กับกระบวนการ Cross-Validation ระบบจะเรียก `fit()` ของทุกขั้นตอนใหม่ในแต่ละ Fold โดยใช้เฉพาะข้อมูลชุดฝึกของ Fold นั้น จึงรับประกันได้ว่าค่าสถิติที่ใช้แปลงข้อมูลไม่ได้มาจากชุดตรวจสอบ

`ColumnTransformer` ทำหน้าที่กำหนดว่าคอลัมน์กลุ่มใดจะผ่านการแปลงแบบใด ในโครงงานนี้กำหนดให้คอลัมน์ Fingerprint จำนวน 1,024 คอลัมน์ผ่านแบบ `passthrough` คือไม่แปลง และคอลัมน์ Lipinski จำนวน 4 คอลัมน์ผ่าน `StandardScaler`

2.5 การประเมินประสิทธิภาพแบบจำลอง

2.5.1 ตัวชี้วัด

ตารางที่ 2.2 ตัวชี้วัดประสิทธิภาพที่ใช้ในโครงงาน

ตัวชี้วัด	สูตร	การตีความ
R^2	$1 - \frac{SS_{res}}{SS_{tot}}$	สัดส่วนความแปรปรวนที่แบบจำลองอธิบายได้ ค่าสูงสุด 1.0 ค่าติดลบหมายถึงแย่กว่าการทำนายด้วยค่าเฉลี่ย
RMSE	$\sqrt{\frac{1}{n}\sum(y_i - \hat{y}_i)^2}$	รากที่สองของค่าเฉลี่ยความคลาดเคลื่อนกำลังสอง ให้น้ำหนักกับความคลาดเคลื่อนขนาดใหญ่
MAE	$\frac{1}{n}\sum\lvert y_i - \hat{y}_i\rvert$	ค่าเฉลี่ยความคลาดเคลื่อนสัมบูรณ์ ทนต่อค่าผิดปกติมากกว่า RMSE
Spearman ρ	สหสัมพันธ์อันดับ	ความสามารถในการจัดอันดับสาร ซึ่งสำคัญกว่าค่าสัมบูรณ์ในงานคัดกรองยา

ในบริบท QSAR ค่า RMSE และ MAE มีหน่วยเป็น log unit ค่า RMSE = 0.5 หมายความว่าโดยเฉลี่ยแบบจำลองทำนายคลาดเคลื่อนประมาณ 3 เท่าของค่า IC_{50} จริง

2.5.2 K-Fold Cross-Validation

การแบ่งชุดข้อมูลฝึกออกเป็น K ส่วนเท่า ๆ กัน แล้วฝึกแบบจำลอง K ครั้ง โดยแต่ละครั้งใช้ $K-1$ ส่วนเป็นข้อมูลฝึกและ 1 ส่วนเป็นข้อมูลตรวจสอบ ผลลัพธ์ที่ได้จึงมีความน่าเชื่อถือมากกว่าการแบ่งครั้งเดียว และค่าส่วนเบี่ยงเบนมาตรฐานข้าม Fold ยังบ่งบอกความเสถียรของแบบจำลอง

ส่วนต่างระหว่าง R^2 ของชุดฝึกกับชุดตรวจสอบ (Train$-$CV Gap) เป็นดัชนีบ่งชี้การเรียนรู้เกิน ค่ายิ่งสูงแสดงว่าแบบจำลองจดจำข้อมูลฝึกมากเกินไป

2.5.3 Scaffold Split

Bemis และ Murcko (1996) เสนอแนวคิดการสกัดโครงสร้างแกนกลางของโมเลกุล (Molecular Framework) โดยตัดหมู่แทนที่ด้านข้างออก เหลือเฉพาะระบบวงแหวนและสายเชื่อม

Sheridan (2013) ชี้ว่าการแบ่งข้อมูลแบบสุ่มในงาน QSAR ทำให้สารในอนุกรมเคมีเดียวกัน (Analog Series) กระจายอยู่ทั้งชุดฝึกและชุดทดสอบ ส่งผลให้ค่า R^2 สูงเกินจริง เพราะแบบจำลอง

เพียงต้องจดจำอนุกรมนั้นแทนที่จะเรียนรู้ความสัมพันธ์เชิงโครงสร้างที่แท้จริง การแบ่งข้อมูลโดยจัดโมเลกุลที่มี Scaffold เดียวกันไว้ฝั่งเดียวกันจึงสะท้อนสถานการณ์การทำนายสารใหม่ได้ตรงกว่า

2.5.4 Applicability Domain

Applicability Domain คือขอบเขตของปริภูมิเคมีที่แบบจำลองมีความน่าเชื่อถือ วิธีประเมินที่นิยมคือการคำนวณความคล้ายคลึงแบบ Tanimoto ระหว่างสารที่ต้องการทำนายกับสารที่ใกล้ที่สุดในชุดข้อมูลฝึก ดังสมการที่ 2.2

$$T(A, B) = \frac{|A \cap B|}{|A \cup B|} \tag{2.2}$$

โดยทั่วไปหากค่าความคล้ายคลึงสูงสุดต่ำกว่า 0.4 ถือว่าสารนั้นอยู่นอกขอบเขตการใช้งานและผลทำนายไม่ควรนำไปใช้เป็นค่าสัมบูรณ์

2.6 การอธิบายแบบจำลองด้วย SHAP

SHAP (SHapley Additive exPlanations) พัฒนาโดย Lundberg และ Lee (2017) เป็นวิธีอธิบายการตัดสินใจของแบบจำลองบนพื้นฐานทฤษฎีเกมสหกรณ์ โดยคำนวณค่า Shapley ซึ่งเป็นการกระจายผลตอบแทนให้ผู้เล่นแต่ละคนอย่างยุติธรรมตามการมีส่วนร่วม

ในบริบทของการเรียนรู้ของเครื่อง ผู้เล่นคือคุณลักษณะแต่ละตัว และผลตอบแทนคือค่าที่แบบจำลองทำนาย ค่า SHAP ของคุณลักษณะ j ในตัวอย่าง i เขียนแทนด้วย $\phi_j^{(i)}$ ซึ่งบอกว่าคุณลักษณะนั้นผลักดันการทำนายให้สูงขึ้นหรือต่ำลงเท่าใดเมื่อเทียบกับค่าฐาน ความสำคัญโดยรวมของคุณลักษณะคำนวณจากค่าเฉลี่ยสัมบูรณ์ดังสมการที่ 2.3

$$\text{Importance}_j = \frac{1}{N} \sum_{i=1}^{N} \left| \phi_j^{(i)} \right| \tag{2.3}$$

สำหรับแบบจำลองประเภทต้นไม้ สามารถใช้ `TreeExplainer` ซึ่งคำนวณค่า SHAP ได้อย่างแม่นยำในเวลาพหุนาม แทนที่จะต้องประมาณค่า

Rodríguez-Pérez และ Bajorath (2020) ได้ประยุกต์ใช้ค่า Shapley ในการตีความการทำนายฤทธิ์ของสารประกอบ และแสดงให้เห็นว่าวิธีนี้สามารถเชื่อมโยงผลการทำนายกลับไปยังโครงสร้างย่อยที่ตีความเชิงเคมีได้

2.7 งานวิจัยที่เกี่ยวข้อง

Nantasenamat และคณะ (2010) ได้สรุปภาพรวมเชิงปฏิบัติของงาน QSAR โดยเน้นความสำคัญของการเตรียมข้อมูล การเลือกคุณลักษณะ และการตรวจสอบความถูกต้องของแบบจำลอง งานนี้

เป็นกรอบแนวคิดพื้นฐานที่โครงงานปัจจุบันยึดถือ

Gaulton และคณะ (2017) ได้อธิบายโครงสร้างและการใช้งานฐานข้อมูล ChEMBL ซึ่งเป็นฐานข้อมูลสารออกฤทธิ์ทางชีวภาพที่ผ่านการดูแลด้วยมือ (Manually Curated) ครอบคลุมข้อมูลจากวรรณกรรมเคมียาและสิทธิบัตร ประเด็นสำคัญที่งานนี้ชี้ไว้คือ ข้อมูลใน ChEMBL มาจากหลายห้องปฏิบัติการที่ใช้โปรโตคอลต่างกัน จึงมีความแปรปรวนภายในสูง จำเป็นต้องกรองและยุบข้อมูลซ้ำอย่างระมัดระวัง

Maggiora (2006) ได้อธิบายปรากฏการณ์ Activity Cliff ซึ่งเป็นกรณีที่โมเลกุลมีโครงสร้างคล้ายกันมากแต่มีฤทธิ์แตกต่างกันอย่างมาก ปรากฏการณ์นี้เป็นข้อจำกัดเชิงหลักการของแบบจำลอง QSAR ที่ตั้งอยู่บนสมมติฐานว่าโครงสร้างที่คล้ายกันควรมีฤทธิ์ใกล้เคียงกัน

ช่องว่างที่โครงงานนี้เติมเต็ม

งานวิจัย QSAR จำนวนมากรายงานเฉพาะผลการแบ่งข้อมูลแบบสุ่มและไม่ได้ประเมินขอบเขตการใช้งานของแบบจำลอง โครงงานนี้จึงรายงานผลทั้งการแบ่งแบบสุ่มและแบบ Scaffold ควบคู่กัน พร้อมทดสอบข้ามชุดข้อมูลกับสารจากแหล่งอิสระ และวิเคราะห์ Applicability Domain เชิงปริมาณ เพื่อให้ได้ภาพความสามารถทำนายที่ตรงกับความเป็นจริงในทางปฏิบัติ

บทที่ 3

วิธีดำเนินการวิจัย

3.1 กรอบการดำเนินงาน

การดำเนินงานแบ่งเป็น 9 ระยะ (Phase 0–8) ตามลำดับดังนี้

ตารางที่ 3.1 ระยะการดำเนินงานทั้ง 9 ระยะ

ระยะ	ชื่อระยะ	ผลผลิตหลัก
Phase 0	เตรียมสภาพแวดล้อมและตรวจสอบชุดข้อมูล	`requirements.txt`, รายงานตรวจสอบข้อมูล
Phase 1	รวบรวมข้อมูลจาก ChEMBL และกรอง assay	`chembl_*_ic50_raw.csv`
Phase 2	ทำความสะอาดข้อมูล 13 ขั้นตอน	`clean_bioactivity_master.csv`
Phase 3	สกัดคุณลักษณะ 1,028 มิติ	`features_hybrid.parquet`, `bitinfo.pkl`
Phase 4	สำรวจข้อมูลเชิงพรรณนา (EDA)	ภาพที่ 4.1–4.4
Phase 5	สร้าง Pipeline และ 5-Fold CV (E1–E5b)	`tbl02_cv_results.csv`
Phase 6	ปรับจูนและประเมินบนชุดทดสอบ	`tbl03_test_results.csv`, แบบจำลอง
Phase 7	วิเคราะห์ SHAP และ SAR	ภาพที่ 4.8–4.11, ตารางวิเคราะห์ SAR
Phase 8	ทดสอบข้ามชุดข้อมูลและจัดทำรายงาน	ภาพที่ 4.12–4.13, รายงานฉบับสมบูรณ์

3.2 เครื่องมือที่ใช้

3.2.1 ฮาร์ดแวร์

เครื่องคอมพิวเตอร์หน่วยประมวลผลกลาง 4 คอร์ หน่วยความจำหลัก 16 GB ระบบปฏิบัติการ Windows 11

3.2.2 ซอฟต์แวร์

จัดทำสภาพแวดล้อมเสมือน (Virtual Environment) เฉพาะโครงงานที่ `.venv/` และตรึงเวอร์ชันไว้ใน `requirements.txt` เพื่อความสามารถทำซ้ำได้

ตารางที่ 3.2 ซอฟต์แวร์และไลบรารีที่ใช้

ไลบรารี	เวอร์ชัน	หน้าที่
Python	3.13.5	ภาษาโปรแกรมหลัก
RDKit	2026.3.6	จัดการโครงสร้างเคมี สกัด Fingerprints วาดภาพโมเลกุล
Scikit-learn	1.7.2	Pipeline, ColumnTransformer, Cross-Validation, RF, SVR
XGBoost	3.4.1	แบบจำลอง Gradient Boosting
SHAP	0.52.0	คำนวณค่า Feature Attribution
pandas	2.3.2	จัดการข้อมูลตาราง
NumPy	2.2.6	คำนวณเชิงตัวเลข
SciPy	1.16.3	สถิติ Mann-Whitney U และ Spearman ρ
Matplotlib	3.11.1	สร้างกราฟ
Seaborn	0.13.2	ธีมและกราฟเชิงสถิติ
PyArrow	25.0.1	อ่านและเขียนไฟล์ Parquet
joblib	1.5.2	บันทึกและโหลดแบบจำลอง

การควบคุมความสามารถทำซ้ำได้กำหนดค่า `RANDOM_STATE = 42` ที่ไฟล์ `src/config.py` และส่งต่อไปยังทุกจุดที่มีการสุ่ม ได้แก่ `train_test_split`, `KFold`, `RandomForestRegressor`, `XGBRegressor` และ `RandomizedSearchCV`

3.3 การตรวจสอบชุดข้อมูลที่ได้รับมอบ

ก่อนเริ่มดำเนินงาน คณะผู้จัดทำได้ตรวจสอบชุดข้อมูลที่มีอยู่ในโฟลเดอร์ `Data_set/` จำนวน 5 ไฟล์ เพื่อประเมินความเหมาะสมกับวัตถุประสงค์ ผลการตรวจสอบสรุปดังตารางที่ 3.3

ตารางที่ 3.3 ผลการตรวจสอบชุดข้อมูลที่ได้รับมอบ

ไฟล์	ขนาด	ปัญหาที่พบ	การตัดสินใจ
`mergedreal.csv`	$469 \times 4{,}264$	มี SMILES ไม่ซ้ำเพียง **10 ตัว** (แถวซ้ำ 459 แถว) เป็นกรดอะมิโนและสารธรรมชาติ ไม่ใช่สารยับยั้ง M^{pro}	ตัดออก
`xfinal.csv`	469×302	เป็น subset ของไฟล์ข้างต้นที่ผ่าน Feature Selection บนข้อมูลทั้งชุด จึงมี Leakage ฝังมา	ตัดออก
`DDH Data.csv`	104×3	หน่วยเป็น μM ไม่ใช่ nM และมี 10 แถวเป็นข้อความ `BLINDED`	ใช้เป็น External Validation
`DDH Data with Properties.csv`	104×40	Descriptors จาก PubChem มีค่าหาย 3 แถว และ 1 แถวมี MW = 0	คำนวณใหม่ด้วย RDKit
`molecule_classification_dataset.csv`	$1{,}333 \times 10$	เป้าหมายเป็น DRD2/HDAC1/BACE1 ไม่ใช่ COVID และไม่มีค่าฤทธิ์เชิงปริมาณ	ใช้เป็นชุดอ้างอิงปริภูมิเคมี

จากผลการตรวจสอบพบว่า **ไม่มีไฟล์ใดตรงตามข้อกำหนดของวัตถุประสงค์** ซึ่งระบุว่าต้องใช้ข้อมูล SARS-CoV-2 M^{pro} จาก ChEMBL ที่มี IC_{50} หน่วย nM คณะผู้จัดทำจึงตัดสินใจรวบรวมข้อมูลหลักใหม่จาก ChEMBL โดยตรง และปรับใช้ชุดข้อมูลเดิมในบทบาทสนับสนุน โดยจัดเป็นสถาปัตยกรรมข้อมูลสามชั้น

1. **ชั้นที่ 1 (ชุดหลัก)** ข้อมูลจาก ChEMBL เป้าหมาย `CHEMBL4523582` ใช้สำหรับฝึกและทดสอบแบบจำลอง
2. **ชั้นที่ 2 (ชุดทดสอบข้ามแหล่ง)** ข้อมูล DDH 94 สาร ใช้ทดสอบความสามารถทำนายข้ามชุดข้อมูล โดยไม่แตะจนกว่าจะสรุปแบบจำลองสุดท้ายแล้ว
3. **ชั้นที่ 3 (ชุดอ้างอิงบริบท)** ข้อมูล MultiTarget 1,333 สาร ใช้เปรียบเทียบปริภูมิเคมีและทดสอบ Applicability Domain

3.4 การรวบรวมข้อมูล

3.4.1 การเลือกเป้าหมาย

ตรวจสอบเป้าหมายผ่าน ChEMBL Web Services พบว่า `CHEMBL4523582` คือ *Replicase polyprotein 1ab* ของ SARS-CoV-2 (UniProt P0DTD1) ประเภท SINGLE PROTEIN ซึ่งมีข้อมูล IC_{50} ทั้งสิ้น 6,220 รายการ เมื่อกรองเฉพาะหน่วย nM เหลือ 6,050 รายการ และเมื่อกรองเฉพาะความสัมพันธ์เท่ากับ (=) เหลือ 4,867 รายการ

3.4.2 การกรอง assay เฉพาะ $3CL^{pro}$

เนื่องจาก `CHEMBL4523582` ครอบคลุมพอลิโปรตีนทั้งเส้นซึ่งมีหลายโดเมนเอนไซม์ (nsp3/PLpro, nsp5/M^{pro}, nsp12/RdRp และอื่น ๆ) จึงจำเป็นต้องกรองเฉพาะ assay ที่วัดฤทธิ์ต่อ M^{pro} โดยใช้นิพจน์ปกติ (Regular Expression) บนฟิลด์ `assay_description` ดังนี้

```
3CL | 3C-like | 3C like | Mpro | M\s*pro | main\s+protease
```

3.4.3 การเตรียมชุด DDH

อ่านไฟล์ `DDH Data.csv` แยกแถวที่มีค่า `BLINDED` จำนวน 10 แถวออกเป็นชุดสาธิตการทำนาย และแปลงหน่วยของ 94 แถวที่เหลือด้วยความสัมพันธ์ $pIC_{50}(\text{มาตรฐาน}) = pIC_{50}(\mu\text{M basis}) + 6$

3.5 การทำความสะอาดข้อมูล

ดำเนินการตามลำดับ 13 ขั้นตอนอย่างเคร่งครัด ดังตารางที่ 3.4

ตารางที่ 3.4 ขั้นตอนการทำความสะอาดข้อมูล 13 ขั้น

ขั้น	การดำเนินการ	เหตุผล
1	ตัดแถวที่ SMILES หรือค่า IC_{50} เป็นค่าว่าง	ข้อมูลไม่สมบูรณ์
2	ตัดแถวที่มี `data_validity_comment`	ChEMBL ระบุเองว่าข้อมูลน่าสงสัย
3	ตัดแถวที่ค่า $IC_{50} \leq 0$	ค่าเป็นไปไม่ได้ทางกายภาพ
4	แปลง SMILES เป็นวัตถุโมเลกุลด้วย RDKit	ตรวจความถูกต้องเชิงเคมี
5	Salt Stripping ด้วย `LargestFragmentChooser`	เลือกเฉพาะส่วนที่ออกฤทธิ์ ตัดไอออนคู่ออก
6	Normalize และ Uncharge	ทำให้รูปแบบการเขียนหมู่ฟังก์ชันเป็นมาตรฐาน
7	แปลงเป็น Canonical SMILES	โมเลกุลเดียวกันต้องได้สายอักขระเดียวกัน
8	คำนวณ InChIKey	ใช้เป็นกุญแจยุบข้อมูลซ้ำ แม่นกว่า SMILES
9	คำนวณ $pIC_{50} = 9 - \log_{10}(IC_{50}[\text{nM}])$	แปลงเป็นตัวแปรตาม
10	ยุบข้อมูลซ้ำตาม InChIKey ด้วยค่ามัธยฐาน และตัดกลุ่มที่ SD > 1.0 log unit	ข้อมูลจากหลายห้องปฏิบัติการอาจขัดแย้งกัน
11	กรองช่วง $3.0 \leq pIC_{50} \leq 11.0$	ตัดค่าที่อยู่นอกช่วงสมเหตุสมผล
12	ตัดโมเลกุลที่มีอะตอมหนัก < 5 หรือ > 70	ตัดชิ้นส่วนเล็กเกินและโมเลกุลใหญ่ผิดปกติ
13	เพิ่มคอลัมน์กลุ่มฤทธิ์	ใช้สำหรับ EDA และ Stratified Split

การเลือกใช้ **ค่ามัธยฐาน** แทนค่าเฉลี่ยในขั้นที่ 10 เนื่องจากค่ามัธยฐานทนต่อค่าผิดปกติได้ดีกว่า และการตัดกลุ่มที่มีส่วนเบี่ยงเบนมาตรฐานเกิน 1.0 log unit ออก เป็นการกำจัดข้อมูลที่แหล่งต้นทางขัดแย้งกันเองจนไม่น่าเชื่อถือ

เกณฑ์การแบ่งกลุ่มฤทธิ์กำหนดเป็น active เมื่อ $pIC_{50} \geq 6.0$, intermediate เมื่อ $5.0 \leq pIC_{50} < 6.0$ และ inactive เมื่อ $pIC_{50} < 5.0$

ตารางที่ 3.5 โครงสร้างคอลัมน์ของชุดข้อมูลมาตรฐาน `clean_bioactivity_master.csv`

คอลัมน์	ชนิด	คำอธิบาย
`molecule_chembl_id`	ข้อความ	รหัสอ้างอิงใน ChEMBL
`canonical_smiles`	ข้อความ	SMILES มาตรฐานหลังทำความสะอาด
`inchikey`	ข้อความ	กุญแจยุบข้อมูลซ้ำ
`ic50_nM`	ทศนิยม	ค่ามัธยฐานหลังยุบซ้ำ
`pIC50`	ทศนิยม	ตัวแปรตาม
`n_records`	จำนวนเต็ม	จำนวน record ต้นทางที่ยุบมา
`pIC50_std`	ทศนิยม	ส่วนเบี่ยงเบนมาตรฐานภายในกลุ่ม
`n_heavy`	จำนวนเต็ม	จำนวนอะตอมหนัก
`bioactivity_class`	ข้อความ	active / intermediate / inactive
`source`	ข้อความ	แหล่งข้อมูล

3.6 การสกัดคุณลักษณะ

สกัด Morgan Fingerprints ด้วยฟังก์ชันของ RDKit โดยกำหนดรัศมีเท่ากับ 2 และขนาดเวกเตอร์เท่ากับ 1,024 บิต พร้อมเก็บข้อมูลการจับคู่บิตกับอะตอมของทุกโมเลกุลไว้ในไฟล์ `bitinfo.pkl` เพื่อใช้วาดภาพโครงสร้างย่อยในระยะที่ 7

คำนวณ Lipinski Descriptors 4 ตัว ได้แก่ MW, LogP, HBD และ HBA ด้วยฟังก์ชันของ RDKit รวมได้เมทริกซ์คุณลักษณะขนาด 1,028 มิติ

ข้อควรระวังสำคัญ

ไม่ดำเนินการตัดบิตที่มีความแปรปรวนต่ำนอก Pipeline บนข้อมูลทั้งชุด เนื่องจากจะก่อให้เกิด Feature Selection Leakage แบบเดียวกับที่ตรวจพบในไฟล์ `xfinal.csv` นอกจากนี้ไม่นำค่า `lipinski_violations` มาใช้เป็นคุณลักษณะ เพราะเป็นฟังก์ชันของ 4 ตัวแรกจึงซ้ำซ้อน

3.7 การสำรวจข้อมูล

ดำเนินการสำรวจข้อมูลเชิงพรรณนา ประกอบด้วยการวิเคราะห์การแจกแจงของ pIC_{50} การเปรียบเทียบปริภูมิเคมีบนแกน MW–LogP การทดสอบความแตกต่างของ Lipinski Descriptors ระหว่างกลุ่มฤทธิ์ด้วยสถิติ Mann-Whitney U การสกัดโครงสร้างแกนกลาง Murcko และการเปรียบเทียบปริภูมิเคมีของชุดข้อมูลทั้งสามชั้น

เลือกใช้สถิติ Mann-Whitney U ซึ่งเป็นสถิติแบบไม่อิงพารามิเตอร์ เนื่องจากไม่ทราบแน่ชัดว่าการแจกแจงของ descriptors เป็นแบบปกติหรือไม่

3.8 การแบ่งข้อมูล

3.8.1 Random Split

แบ่งข้อมูลเป็นชุดฝึกร้อยละ 75 และชุดทดสอบร้อยละ 25 ด้วย `train_test_split` โดยกำหนด `stratify` ตามคอลัมน์กลุ่มฤทธิ์ เพื่อให้สัดส่วน active/intermediate/inactive เท่ากันทั้งสองฝั่ง

3.8.2 Scaffold Split

สกัดโครงสร้างแกนกลาง Bemis–Murcko ของทุกโมเลกุล จัดกลุ่มตาม Scaffold แล้วเรียงลำดับกลุ่มจากใหญ่ไปเล็ก จากนั้นทยอยจัดกลุ่มใหญ่เข้าชุดฝึกก่อนจนเต็มโควตา ส่วนที่เหลือเข้าชุดทดสอบ วิธีนี้ทำให้ชุดทดสอบประกอบด้วยโครงสร้างแกนกลางที่พบไม่บ่อยและไม่ปรากฏในชุดฝึกเลย

3.9 การสร้าง Pipeline ป้องกันการรั่วไหล

โครงสร้าง Pipeline ประกอบด้วยสองขั้นตอนหลัก ดังโค้ดต่อไปนี้

```
preprocessor = ColumnTransformer([
    ('fp',   'passthrough',    FP_COLS),     # 1,024 bits: no scaling
    ('desc', StandardScaler(), DESC_COLS),   # scale 4 descriptors
], remainder='drop')

pipe = Pipeline([
    ('prep',  preprocessor),
    ('model', estimator),
])
```

เมื่อส่ง Pipeline นี้เข้าสู่ `cross_validate` ระบบจะเรียก `pipe.fit()` ใหม่ในทุก Fold โดยใช้เฉพาะข้อมูลชุดฝึกของ Fold นั้น ทำให้ค่าเฉลี่ยและส่วนเบี่ยงเบนมาตรฐานที่ `StandardScaler` ใช้ไม่ได้รับอิทธิพลจากชุดตรวจสอบ

3.10 การออกแบบการทดลอง

ตารางที่ 3.6 การออกแบบการทดลอง E1–E6

รหัส	การแบ่งข้อมูล	คุณลักษณะ	แบบจำลอง	จุดประสงค์
E1	Random 75/25	1,028 (Hybrid)	4 แบบจำลอง	ผลหลักตอบวัตถุประสงค์ที่ 1
E2	Scaffold 75/25	1,028 (Hybrid)	4 แบบจำลอง	ทดสอบเข้มงวด
E3	Random 75/25	1,024 (FP เท่านั้น)	Random Forest	Ablation: Lipinski มีค่าเพิ่มหรือไม่
E4	Random 75/25	4 (Lipinski เท่านั้น)	Random Forest	Ablation: FP มีค่าเพิ่มเท่าใด
E5	Random 75/25	1,028	SVR	พิสูจน์ Preprocessing Leakage
E5b	Random 75/25	300 (SelectKBest)	Random Forest	พิสูจน์ Feature Selection Leakage
E6	—	1,028	แบบจำลองที่ดีที่สุด	ทดสอบข้ามชุดข้อมูล

การทดลอง E5b ออกแบบให้จำลองสถานการณ์เดียวกับไฟล์ `xfinal.csv` ที่ตรวจพบในระยะที่ 0 กล่าวคือคัดเลือกคุณลักษณะ 300 ตัวจากทั้งหมดโดยพิจารณาความสัมพันธ์กับตัวแปรตามบนข้อมูลทั้งชุดก่อนแบ่งข้อมูล แล้วเปรียบเทียบกับกรณีที่ทำการคัดเลือกภายใน Pipeline

3.11 การปรับจูนไฮเปอร์พารามิเตอร์

ใช้ `RandomizedSearchCV` บนชุดฝึกเท่านั้น โดยประเมินด้วย 5-Fold Cross-Validation และใช้ R^2 เป็นเกณฑ์คัดเลือก เหตุผลที่เลือก `RandomizedSearchCV` แทน `GridSearchCV` เนื่องจากข้อจำกัดด้านฮาร์ดแวร์ 4 คอร์ ซึ่งการค้นหาแบบครบทุกชุดค่าของ Random Forest จะใช้เวลาเกินความเหมาะสม

ตารางที่ 3.7 ค่าไฮเปอร์พารามิเตอร์ที่ใช้ค้นหา

แบบจำลอง	พารามิเตอร์	ค่าที่ทดลอง	รอบสุ่ม
Random Forest	`n_estimators`	300, 500, 800	30
	`max_depth`	None, 15, 25	
	`min_samples_split`	2, 5, 10	
	`min_samples_leaf`	1, 2, 4	
	`max_features`	'sqrt', 0.3	
XGBoost	`n_estimators`	300, 600	30
	`learning_rate`	0.03, 0.05, 0.1	
	`max_depth`	4, 6, 8	
	`subsample`	0.8, 1.0	
	`colsample_bytree`	0.6, 0.8	
SVR (RBF)	`C`	1, 10, 100	27
	`gamma`	'scale', 0.001, 0.01	
	`epsilon`	0.05, 0.1, 0.2	

3.12 การประเมินบนชุดทดสอบ

ชุดทดสอบถูกใช้เพียงครั้งเดียวหลังการปรับจูนเสร็จสิ้น ประเมินด้วย R^2, RMSE, MAE และเพิ่ม Spearman ρ ซึ่งวัดความสามารถในการจัดอันดับสาร กำหนดเกณฑ์ตีความล่วงหน้าดังตารางที่ 3.8

ตารางที่ 3.8 เกณฑ์ตีความค่า R^2 ที่กำหนดไว้ล่วงหน้า

ช่วง Test R^2	การตีความ
< 0.40	อ่อน ต้องอภิปรายสาเหตุ
$0.40 - 0.60$	ยอมรับได้สำหรับ QSAR ข้ามชุดข้อมูล ChEMBL
$0.60 - 0.75$	ดี ระดับที่คาดหวังจากโครงงานนี้
> 0.75	ดีมาก ต้องตรวจสอบ Leakage ซ้ำ

3.13 การวิเคราะห์ SHAP และ SAR

ใช้ `shap.TreeExplainer` กับแบบจำลองประเภทต้นไม้ที่ให้ผลดีที่สุด คำนวณค่า SHAP บนชุดทดสอบจำนวน 400 โมเลกุล (สุ่มจาก 550 โมเลกุล) เพื่อควบคุมเวลาประมวลผล ขั้นตอนการจับคู่ย้อนกลับเป็นภาพโครงสร้างย่อยมีดังนี้

1. คัดเลือกบิตที่ติดอันดับ Mean|SHAP| สูงสุด
2. คำนวณค่า SHAP เฉลี่ยเมื่อบิตนั้นมีค่าเป็น 1 เพื่อระบุทิศทาง (เพิ่มหรือลดฤทธิ์)
3. เลือกบิตที่ผลักดันฤทธิ์ขึ้น 3 บิต และผลักดันฤทธิ์ลง 3 บิต
4. ค้นหาโมเลกุลที่มีบิตนั้นและมีค่า |SHAP| สูงสุด
5. วาดภาพด้วย `Draw.DrawMorganBit`
6. คำนวณร้อยละการปรากฏของบิตในกลุ่ม active และ inactive เพื่อยืนยันเชิงสถิติ

3.14 การทดสอบข้ามชุดข้อมูลและ Applicability Domain

นำแบบจำลองที่บันทึกไว้มาทำนายชุด DDH โดยตัดสารที่มี InChIKey ซ้ำกับชุดฝึกออกก่อน จากนั้นวิเคราะห์ Applicability Domain ด้วยการคำนวณค่าความคล้ายคลึง Tanimoto สูงสุดของแต่ละสารเทียบกับสารทั้งหมดในชุดฝึก และเปรียบเทียบระหว่างชุดข้อมูลสามชุด

บทที่ 4

ผลการดำเนินงาน

4.1 ผลการรวบรวมและกรองข้อมูล

การเรียกใช้ ChEMBL Web Services ได้ข้อมูล IC_{50} หน่วย nM ที่มีความสัมพันธ์เท่ากับ จำนวน 4,867 รายการ เมื่อกรอง assay เฉพาะที่วัดฤทธิ์ต่อ $3CL^{pro}$ ได้ผลดังตารางที่ 4.1

ตารางที่ 4.1 ผลการกรอง assay

รายการ	**จำนวน**	**ร้อยละ**
IC_{50} ทั้งหมด (nM, relation =)	4,867	100.0
คงไว้ (assay ระบุ $3CL^{pro}$ / M^{pro})	2,889	59.4
คัดออก	**1,978**	**40.6**

ตัวอย่าง assay ที่ถูกคัดออกเรียงตามความถี่ ได้แก่ การทดสอบที่ระบุเป้าหมายเป็น nsp3 (1,043 รายการ), SARS-CoV-2 PL protease (57 รายการ), PLpro ที่แสดงออกใน *Escherichia coli* (56 รายการ), SARS-CoV-2 PLpro ที่ใช้สับสเตรต Z-RLRGG-AMC (54 รายการ) และ papain-like protease (38 รายการ)

ข้อสังเกต

ผลนี้ยืนยันว่าการกรองระดับ assay เป็นขั้นตอนที่จำเป็นอย่างยิ่ง เนื่องจากเป้าหมาย `CHEMBL4523582` ครอบคลุมพอลิโปรตีนทั้งเส้น หากไม่กรอง แบบจำลองจะเรียนรู้จากข้อมูลที่ปะปนเป้าหมายเอนไซม์คนละชนิดถึงร้อยละ 40.6

4.2 ผลการทำความสะอาดข้อมูล

ตารางที่ 4.2 ผลการทำความสะอาดข้อมูลทีละขั้น

ขั้นตอน	จำนวนแถวคงเหลือ	ลดลง
ข้อมูลนำเข้า	2,889	—
1. ตัดค่าว่าง	2,879	10
2. ตัด `data_validity_comment`	2,843	36
3. ตัดค่า ≤ 0	2,843	0
4–8. แปลงและมาตรฐาน RDKit	2,843	0
9. คำนวณ pIC_{50}	2,843	0
10a. ยุบซ้ำตาม InChIKey	2,248	595
10b. ตัดกลุ่มที่ขัดแย้ง (SD $>$ 1.0)	2,235	13
11. กรองช่วง pIC_{50}	2,235	0
12. กรองจำนวนอะตอมหนัก	2,198	37
ผลลัพธ์สุดท้าย	**2,198**	—

ประเด็นที่น่าสนใจคือ ขั้นตอนการยุบข้อมูลซ้ำลดจำนวนแถวลง 595 แถว แสดงว่ามีโมเลกุลจำนวนมากที่ถูกทดสอบซ้ำหลายครั้ง โดยมีกลุ่มที่มีมากกว่า 1 record จำนวน 225 กลุ่ม ค่ามัธยฐานของส่วนเบี่ยงเบนมาตรฐานภายในกลุ่มอยู่ที่ 0.011 log unit ซึ่งต่ำมาก แสดงว่าข้อมูลส่วนใหญ่มีความสอดคล้องกันดี มีเพียง 13 กลุ่มที่ขัดแย้งกันเกินเกณฑ์ 1.0 log unit จนต้องตัดทิ้ง โมเลกุลที่ถูกทดสอบมากที่สุดมีถึง 34 record

สำหรับชุด DDH ทั้ง 94 สารผ่านทุกขั้นตอนโดยไม่มีการสูญเสีย และเมื่อตรวจสอบการซ้อนทับด้วย InChIKey พบว่ามีสาร **4 ตัวที่ซ้ำกับชุด ChEMBL** จึงตัดออก เหลือ 90 สารสำหรับการทดสอบข้ามชุดข้อมูล ผลนี้ยืนยันว่าการตรวจสอบการซ้อนทับก่อนรายงานผล External Validation เป็นขั้นตอนที่จำเป็น

4.3 ผลการสำรวจข้อมูล

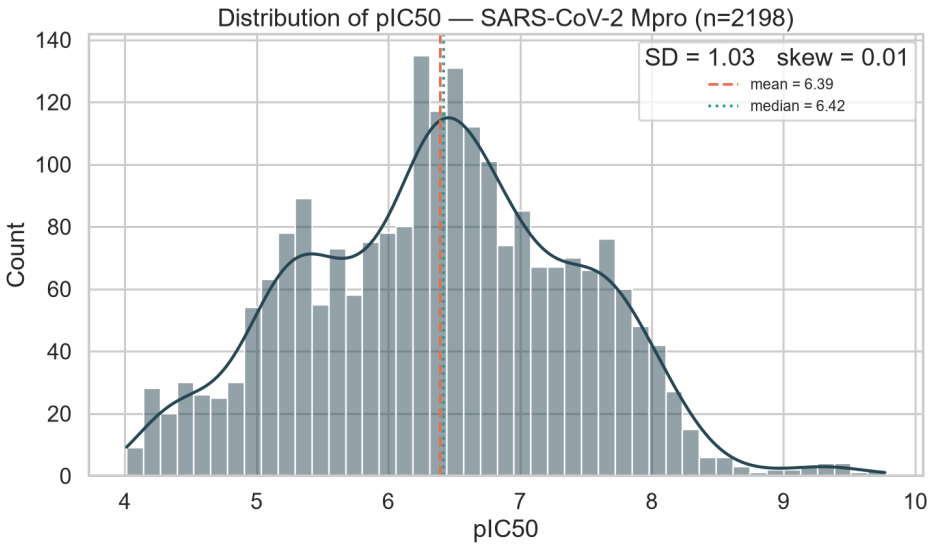
ตารางที่ 4.3 สรุปคุณลักษณะชุดข้อมูล

รายการ	**ChEMBL M^{pro} (ชุดหลัก)**	**DDH COVID (ชุดทดสอบข้าม)**
จำนวนโมเลกุล	2,198	90
pIC_{50} เฉลี่ย	6.393	4.872
ส่วนเบี่ยงเบนมาตรฐาน	1.030	0.824
ค่าต่ำสุด	4.014	3.301
ค่าสูงสุด	9.770	7.222
กลุ่ม active	1,453	10
กลุ่ม intermediate	547	19
กลุ่ม inactive	198	61
Scaffold ไม่ซ้ำ	976 (44.4%)	—
บิตที่ถูกเซ็ตเฉลี่ย	55.2	45.3
บิตที่มีความแปรปรวนเป็นศูนย์	0	—

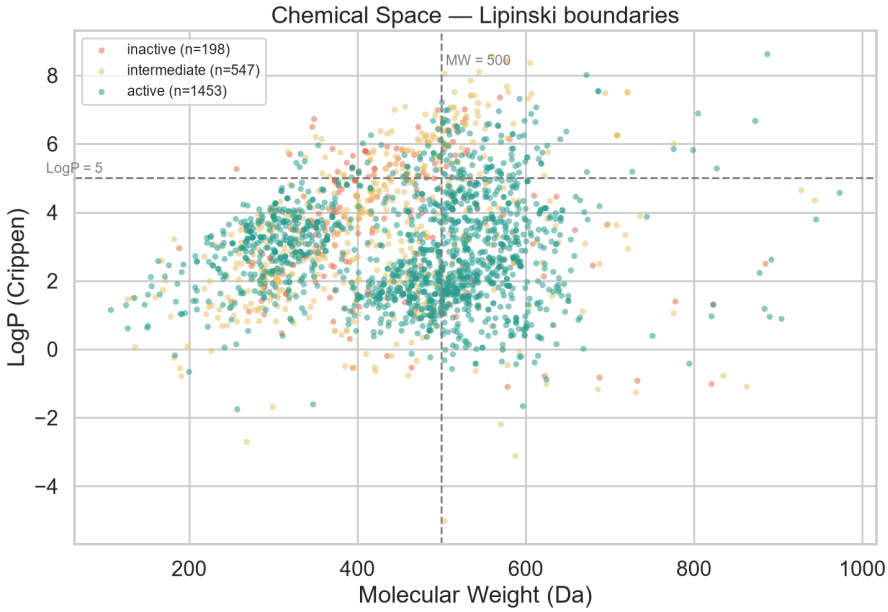
ข้อสังเกตสำคัญสองประการ

ประการแรก ชุดข้อมูลหลักมี Scaffold ไม่ซ้ำถึง 976 แบบจาก 2,198 โมเลกุล คิดเป็นร้อยละ 44.4 แสดงว่าข้อมูลมีความหลากหลายเชิงโครงสร้างสูง ไม่ได้กระจุกตัวอยู่ในอนุกรมเคมีเดียว และไม่มีบิตใดใน 1,024 บิตที่มีความแปรปรวนเป็นศูนย์ จึงใช้คุณลักษณะได้ครบทุกมิติ

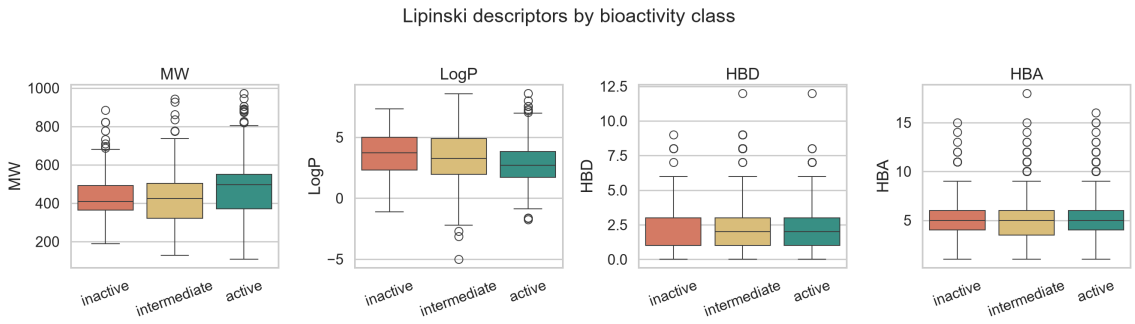
ประการที่สอง ชุด ChEMBL มีความไม่สมดุลของกลุ่มฤทธิ์อย่างชัดเจน โดยมี active ถึง 1,453 ตัว แต่มี inactive เพียง 198 ตัว ขณะที่ชุด DDH มีลักษณะตรงกันข้าม คือมี inactive ถึง 61 จาก 90 ตัว ความแตกต่างนี้เป็นสัญญาณเตือนล่วงหน้าถึงปัญหาที่จะพบในการทดสอบข้ามชุดข้อมูล



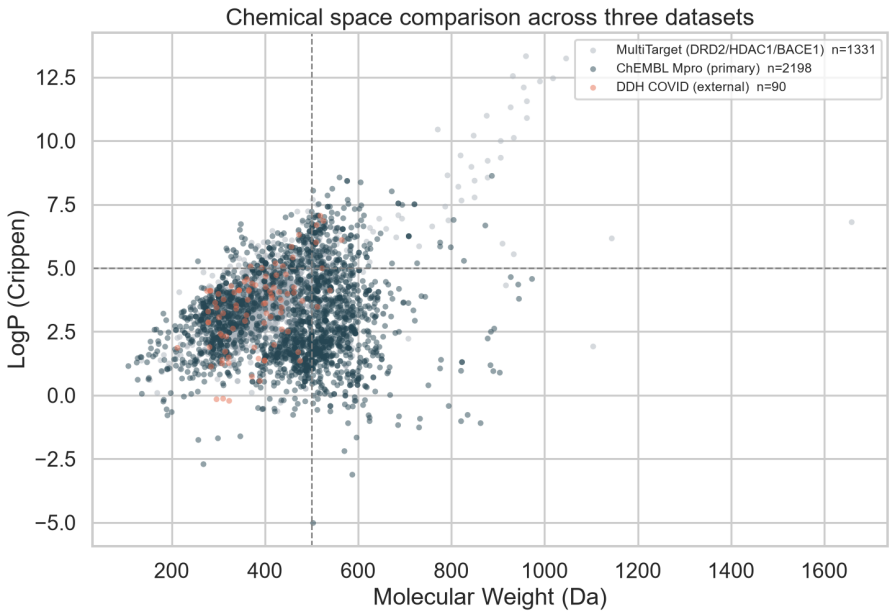
ภาพที่ 4.1 การแจกแจงความถี่ของค่า pIC_{50} ในชุดข้อมูลหลัก



ภาพที่ 4.2 ปริภูมิเคมีระหว่างน้ำหนักโมเลกุลกับค่า LogP แยกตามกลุ่มฤทธิ์



ภาพที่ 4.3 การเปรียบเทียบ Lipinski Descriptors ตามกลุ่มฤทธิ์



ภาพที่ 4.4 การเปรียบเทียบปริภูมิเคมีของชุดข้อมูลสามชุด

ตารางที่ 4.4 โครงสร้างแกนกลาง Murcko 10 อันดับแรก

อันดับ	Murcko Scaffold	จำนวน	ร้อยละ
1	`O=C(Oc1cccnc1)c1ccccc1`	46	2.09
2	`c1ccccc1`	35	1.59
3	`O=C(c1ccccc1)n1cnc2ccccc21`	30	1.36
4	`O=c1c2ccccc2[se]n1-c1ccccc1`	29	1.32
5	`O=c1[nH]c(-c2ccccc2)nc2ccccc12`	27	1.23
6	`O=C(Cn1sc2ccccc2c1=O)Nc1ccccc1`	27	1.23
7	`O=C(NCc1ccccc1)C(Nc1ccc(-c2ccccc2)cc1)c1cccnc1`	27	1.23
8	`O=C1NCCC1CCNC(=O)C1C2CC2CN1C(=O)c1cc2ccccc2[nH]1`	25	1.14
9	`O=C(NC(Cc1ccccc1)C(=O)NNCc1ccccc1)OCc1ccccc1`	23	1.05
10	`c1ccc(-c2cccc3c2CCc2c(-c4ccccn4)cccc2-3)cc1`	22	1.00

ไม่มี Scaffold ใดที่ครองสัดส่วนเกินร้อยละ 2.1 ซึ่งยืนยันความหลากหลายของชุดข้อมูลอีกครั้ง Scaffold อันดับ 8 มีลักษณะเป็นโครงสร้างเปปไทด์คล้าย ซึ่งสอดคล้องกับสารยับยั้ง M^{pro} กลุ่มหลักที่พัฒนากันอยู่

ตารางที่ 4.5 การเปรียบเทียบ Lipinski Descriptors ด้วย Mann-Whitney U (active เทียบ inactive)

Descriptor	มัธยฐาน active	มัธยฐาน inactive	สถิติ U	ค่า p
MW	496.39	409.49	177,509.5	8.85×10^{-8}
LogP	2.710	3.725	106,106.5	2.01×10^{-9}
HBD	2.00	1.00	165,977.5	3.38×10^{-4}
HBA	5.00	5.00	160,018.5	8.86×10^{-3}

ทุก descriptor แตกต่างกันอย่างมีนัยสำคัญทางสถิติที่ระดับ 0.01 โดยพบรูปแบบที่ชัดเจน คือ สารกลุ่ม active มี **น้ำหนักโมเลกุลสูงกว่า** (มัธยฐาน 496 เทียบกับ 409 Da) และ **ค่า LogP ต่ำกว่า** (2.71 เทียบกับ 3.73) สารกลุ่ม inactive อย่างมีนัยสำคัญ

รูปแบบนี้สอดคล้องกับความรู้ทางเคมียาที่ว่า สารยับยั้ง M^{pro} ที่มีประสิทธิภาพมักเป็นโมเลกุลขนาดใหญ่ที่มีลักษณะคล้ายเปปไทด์ มีซั้วค่อนข้างสูง และมีหมู่ที่สร้างพันธะไฮโดรเจนกับกรดอะมิโนในช่องจับของเอนไซม์ได้ดี สังเกตได้จากค่า HBD ที่สูงกว่า อย่างไรก็ตาม น้ำหนักโมเลกุลมัธยฐานของสาร active ที่ 496 Da นั้นเกือบชนขีดจำกัดของกฎลิพินสกีที่ 500 Da ซึ่งสะท้อนความท้าทายในการพัฒนาสารกลุ่มนี้ให้เป็นยารับประทาน

4.4 ผลการทำ Cross-Validation

การแบ่งข้อมูลได้ผลดังนี้ Random Split ให้ชุดฝึก 1,648 โมเลกุลและชุดทดสอบ 550 โมเลกุล ส่วน Scaffold Split ให้ชุดฝึก 1,649 โมเลกุลและชุดทดสอบ 549 โมเลกุล

ตารางที่ 4.6 ผล 5-Fold Cross-Validation บนชุดฝึก Random Split (E1)

แบบจำลอง	CV R^2 (เฉลี่ย $\pm$ SD)	RMSE	MAE	Train R^2	Gap
Dummy Regressor	-0.0021 ± 0.0013	1.0371	0.8395	0.0000	0.0021
Random Forest	$\mathbf{0.5997 \pm 0.0394}$	**0.6544**	0.4481	0.9368	0.3371
XGBoost	0.5803 ± 0.0342	0.6707	0.4531	0.9573	0.3770
SVR (RBF)	0.5994 ± 0.0461	0.6549	**0.4433**	0.9703	0.3709

ตารางที่ 4.7 ผล 5-Fold Cross-Validation บนชุดฝึก Scaffold Split (E2)

แบบจำลอง	CV R^2 (เฉลี่ย $\pm$ SD)	RMSE	MAE	Train R^2	Gap
Dummy Regressor	-0.0037 ± 0.0019	1.0204	0.8173	0.0000	0.0037
Random Forest	0.6670 ± 0.0181	0.5876	0.3993	0.9407	0.2736
XGBoost	0.6527 ± 0.0127	0.6002	0.4035	0.9515	0.2988
SVR (RBF)	$\mathbf{0.6735 \pm 0.0132}$	**0.5820**	**0.3911**	0.9609	0.2875

ในระยะ Cross-Validation แบบจำลองทั้งสามที่ไม่ใช่ Dummy ให้ผลใกล้เคียงกันมาก โดย Random Forest นำเล็กน้อยในกรณี Random Split ค่า Dummy Regressor ที่ได้ R^2 ติดลบเล็กน้อยเป็นไปตามที่คาดในทางทฤษฎี

ส่วนต่างระหว่าง Train R^2 กับ CV R^2 อยู่ในช่วง 0.27–0.38 ในทุกแบบจำลอง แสดงว่ามีการเรียนรู้เกินอยู่พอสมควร โดยเฉพาะ SVR ที่มี Train R^2 สูงถึง 0.9703 ซึ่งเป็นลักษณะปกติของแบบจำลองที่ทำงานบนคุณลักษณะมิติสูง

ตารางที่ 4.8 ผลการศึกษา Ablation

การทดลอง	คุณลักษณะ	จำนวนมิติ	CV R^2	CV RMSE
E4	Lipinski เท่านั้น	4	0.2668	0.8875
E3	Morgan FP เท่านั้น	1,024	0.5885	0.6636
E1	**Hybrid (FP + Lipinski)**	**1,028**	**0.5997**	**0.6544**

ผลการศึกษา Ablation แสดงว่าคุณลักษณะแบบผสมให้ผลดีที่สุด โดยดีกว่าการใช้ Morgan FP อย่างเดียว $+0.0112$ R^2 และดีกว่าการใช้ Lipinski อย่างเดียว $+0.3329$ R^2

ข้อสังเกต

พลังการทำนายส่วนใหญ่มาจาก Morgan Fingerprints ขณะที่ Lipinski Descriptors เพิ่มค่าเพียงเล็กน้อย อย่างไรก็ตาม การเพิ่มขึ้น 0.0112 R^2 จากการเพิ่มคุณลักษณะเพียง 4 มิติ คิดเป็นร้อยละ 0.39 ของจำนวนมิติทั้งหมด ถือว่าคุ้มค่าในเชิงอัตราส่วนต้นทุนต่อผลตอบแทน

ตารางที่ 4.9 ผลการพิสูจน์ Data Leakage

การทดลอง	กรณี	CV R^2	ส่วนต่าง
E5	A ถูกต้อง — ปรับสเกลภายใน Pipeline	0.5994	—
E5	B ผิด — ปรับสเกลก่อนแบ่งข้อมูล	0.5995	**+0.0001**
E5b	A ถูกต้อง — SelectKBest ภายใน Pipeline	0.5892	—
E5b	B ผิด — SelectKBest บนข้อมูลทั้งชุด	0.6008	**+0.0116**

ผลการทดลองนี้เป็นข้อค้นพบที่ต้องรายงานอย่างตรงไปตรงมา เนื่องจากไม่เป็นไปตามที่คาดการณ์ไว้ล่วงหน้า

การทดลอง E5 แสดงว่า Preprocessing Leakage แทบไม่มีผลเลย ส่วนต่างเพียง $+0.0001$ R^2 อธิบายได้จากสองเหตุผล ประการแรก มีเพียง 4 คุณลักษณะจากทั้งหมด 1,028 คุณลักษณะที่ผ่านการปรับสเกล คิดเป็นร้อยละ 0.39 เท่านั้น ประการที่สอง ขนาดชุดฝึก 1,648 ตัวอย่างมีขนาดใหญ่เพียงพอที่ค่าเฉลี่ยและส่วนเบี่ยงเบนมาตรฐานที่คำนวณจากชุดฝึกของแต่ละ Fold แทบไม่ต่างจากที่คำนวณจากข้อมูลทั้งชุด

การทดลอง E5b แสดงว่า Feature Selection Leakage ให้อคติบวกที่วัดได้จริง ส่วนต่าง $+0.0116$ R^2 ซึ่งมากกว่า E5 ถึง 116 เท่า การรั่วไหลรูปแบบนี้ตรงกับสิ่งที่ตรวจพบในไฟล์

`xfinal.csv` ที่ได้รับมอบมา ซึ่งคัดเลือกคุณลักษณะ 300 ตัวจาก 4,262 คอลัมน์บนข้อมูลทั้งชุด ผลการทดลองนี้จึงเป็นหลักฐานเชิงประจักษ์ที่สนับสนุนการตัดสินใจไม่ใช้ไฟล์ดังกล่าว

4.5 ผลการปรับจูนและประเมินบนชุดทดสอบ

ตารางที่ 4.10 ไฮเปอร์พารามิเตอร์ที่ดีที่สุด (Random Split)

แบบจำลอง	**ค่าที่เลือกได้**
Random Forest	`n_estimators`=500, `max_depth`=None, `min_samples_split`=5, `min_samples_leaf`=1, `max_features`=0.3
XGBoost	`n_estimators`=600, `learning_rate`=0.03, `max_depth`=8, `subsample`=0.8, `colsample_bytree`=0.6
SVR (RBF)	`C`=1, `gamma`='scale', `epsilon`=0.05

ตารางที่ 4.11 ผลการประเมินบนชุดทดสอบ Random Split ($n = 550$)

แบบจำลอง	**R^2**	**RMSE**	**MAE**	**Spearman ρ**
Dummy Regressor	-0.0000	1.0074	0.8054	—
Random Forest	0.6822	0.5679	0.4107	0.8351
XGBoost	**0.7034**	**0.5487**	**0.3918**	**0.8415**
SVR (RBF)	0.6716	0.5774	0.4199	0.8257

ตารางที่ 4.12 ผลการประเมินบนชุดทดสอบ Scaffold Split ($n = 549$)

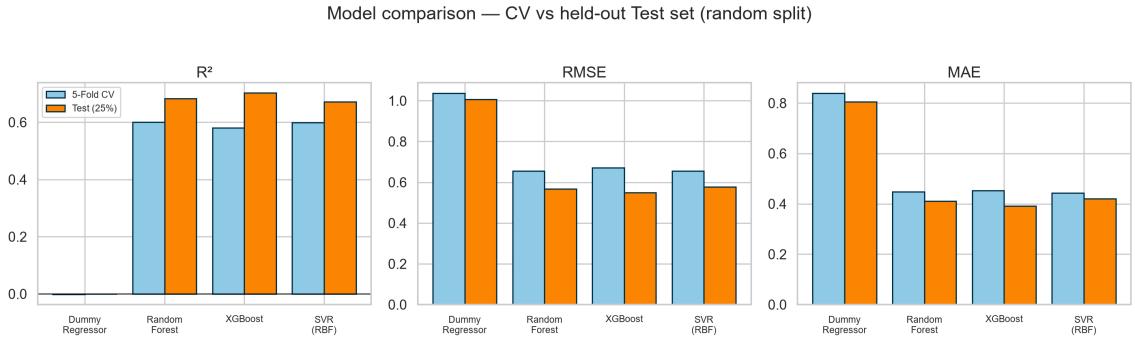
แบบจำลอง	**R^2**	**RMSE**	**MAE**	**Spearman ρ**
Dummy Regressor	-0.0162	1.0611	0.8715	—
Random Forest	0.4949	0.7481	0.5626	0.7414
XGBoost	**0.5127**	**0.7348**	**0.5440**	**0.7452**
SVR (RBF)	0.4637	0.7708	0.5866	0.7057

XGBoost ให้ผลดีที่สุดบนชุดทดสอบทั้งสองวิธีการแบ่ง ซึ่งน่าสนใจเพราะในระยะ Cross-Validation ก่อนปรับจูน XGBoost ทำได้ต่ำที่สุดในสามแบบจำลอง ผลนี้แสดงว่า XGBoost

ได้ประโยชน์จากการปรับจูนไฮเปอร์พารามิเตอร์มากกว่าแบบจำลองอื่น โดยค่าที่เลือกได้คือ `learning_rate` ต่ำที่ 0.03 ร่วมกับจำนวนต้นไม้มากที่ 600 ต้น ซึ่งเป็นการแลกความเร็วกับความแม่นยำ

ประเด็นสำคัญที่สุดของบทนี้

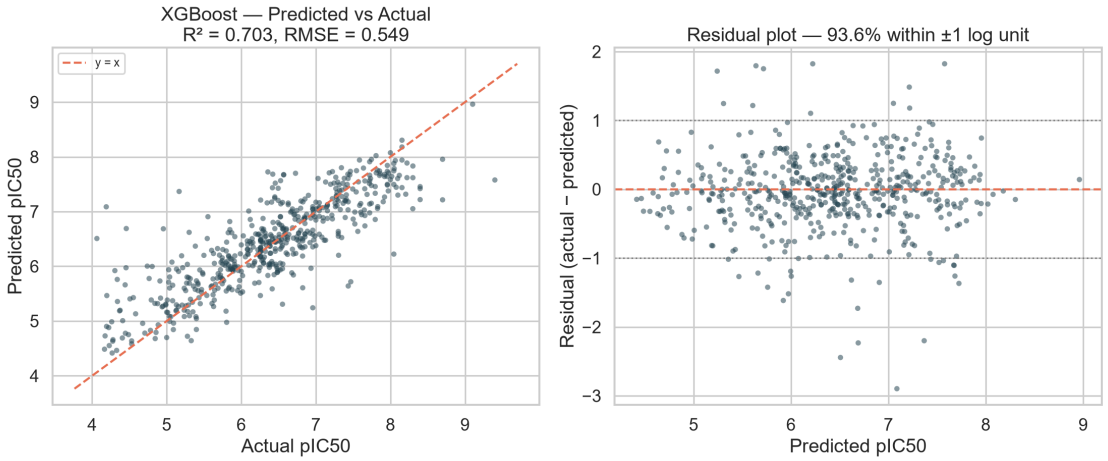
ค่า R^2 ของ XGBoost ลดลงจาก 0.7034 บน Random Split เหลือ 0.5127 บน Scaffold Split คิดเป็นการลดลงร้อยละ 27.1 ส่วนต่างนี้ยืนยันคำเตือนของ Sheridan (2013) ว่าการแบ่งข้อมูลแบบสุ่มให้ค่าที่มองโลกในแง่ดีเกินไป เพราะโมเลกุลในอนุกรมเคมีเดียวกันกระจายอยู่ทั้งสองฝั่ง ในทางปฏิบัติ ตัวเลขที่ควรอ้างอิงเมื่อพูดถึงการทำนายสารที่มีโครงสร้างแกนกลางใหม่คือ $R^2 = 0.5127$ ไม่ใช่ 0.7034



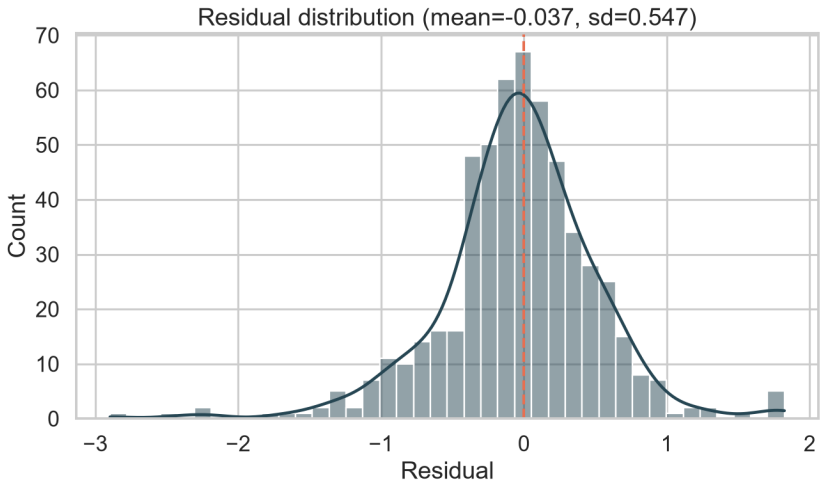
ภาพที่ 4.5 การเปรียบเทียบประสิทธิภาพแบบจำลองระหว่าง Cross-Validation กับชุดทดสอบ

4.6 การวิเคราะห์ค่าคลาดเคลื่อน

ค่าคลาดเคลื่อนโดยรวมของแบบจำลอง XGBoost บนชุดทดสอบ Random Split มีค่าเฉลี่ย -0.0368 และส่วนเบี่ยงเบนมาตรฐาน 0.5479 log unit การทำนายร้อยละ 93.6 มีความคลาดเคลื่อนไม่เกิน 1 log unit และร้อยละ 72.5 ไม่เกิน 0.5 log unit



ภาพที่ 4.6 กราฟค่าทำนายเทียบค่าจริง (ซ้าย) และกราฟค่าคลาดเคลื่อน (ขวา)



ภาพที่ 4.7 การแจกแจงค่าคลาดเคลื่อน

ตารางที่ 4.13 การวิเคราะห์ค่าคลาดเคลื่อนแยกตามกลุ่มฤทธิ์

กลุ่มฤทธิ์	จำนวน	ค่าคลาดเคลื่อนเฉลี่ย	MAE	RMSE
active	364	$+0.1203$	0.3635	0.4926
intermediate	137	-0.2116	0.3481	0.4790
inactive	**49**	**-0.7151**	**0.7246**	**0.9667**

ผลการวิเคราะห์นี้เปิดเผยจุดอ่อนสำคัญของแบบจำลอง กล่าวคือ **แบบจำลองทำนายสารกลุ่ม inactive สูงเกินจริงอย่างเป็นระบบเฉลี่ย 0.72 log unit** และมีค่า RMSE สูงถึง 0.9667 เกือบสองเท่าของอีกสองกลุ่ม

สาเหตุมาจากความไม่สมดุลของชุดข้อมูลฝึก ซึ่งมีสาร active ถึง 1,453 ตัว แต่มี inactive เพียง 198 ตัว คิดเป็นอัตราส่วน 7.3 ต่อ 1 แบบจำลองจึงมีแนวโน้มเอนเอียงไปทางการทำนายค่าสูง

ค่าคลาดเคลื่อนที่มากที่สุดสามอันดับแรกล้วนเป็นสารกลุ่ม inactive ที่ถูกทำนายเป็น active ได้แก่ ค่าจริง 4.190 ทำนาย 7.087 (คลาดเคลื่อน -2.897), ค่าจริง 4.064 ทำนาย 6.508 (คลาดเคลื่อน -2.444) และค่าจริง 4.458 ทำนาย 6.690 (คลาดเคลื่อน -2.232)

ข้อค้นพบนี้มีนัยสำคัญเชิงปฏิบัติ เพราะในงานคัดกรองยา การทำนายสารที่ไม่มีฤทธิ์ว่ามีฤทธิ์ (False Positive) จะทำให้เสียทรัพยากรไปกับการทดสอบสารที่ไม่มีประโยชน์

4.7 ผลการวิเคราะห์ SHAP และ SAR

แบบจำลองที่ใช้วิเคราะห์คือ XGBoost ซึ่งเป็นแบบจำลองประเภทต้นไม้ที่ให้ผลดีที่สุด คำนวณค่า SHAP บนชุดทดสอบ 400 โมเลกุล

ตารางที่ 4.14 ค่าความสำคัญของคุณลักษณะ 20 อันดับแรก

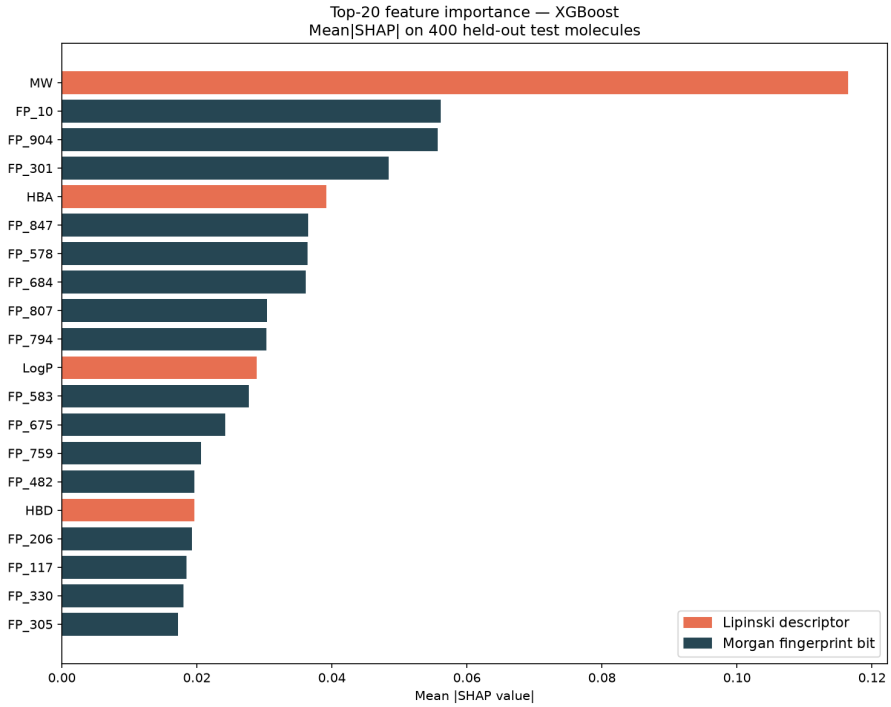
อันดับ	คุณลักษณะ	Mean|SHAP|	ประเภท
1	**MW**	**0.1165**	**Lipinski descriptor**
2	FP_10	0.0561	Morgan fingerprint bit
3	FP_904	0.0557	Morgan fingerprint bit
4	FP_301	0.0484	Morgan fingerprint bit
5	**HBA**	**0.0392**	**Lipinski descriptor**
6	FP_847	0.0365	Morgan fingerprint bit
7	FP_578	0.0364	Morgan fingerprint bit
8	FP_684	0.0361	Morgan fingerprint bit
9	FP_807	0.0304	Morgan fingerprint bit
10	FP_794	0.0303	Morgan fingerprint bit
11	**LogP**	**0.0288**	**Lipinski descriptor**
12	FP_583	0.0277	Morgan fingerprint bit
13	FP_675	0.0242	Morgan fingerprint bit
14	FP_759	0.0207	Morgan fingerprint bit
15	FP_482	0.0196	Morgan fingerprint bit
16	**HBD**	**0.0196**	**Lipinski descriptor**
17	FP_206	0.0193	Morgan fingerprint bit
18	FP_117	0.0184	Morgan fingerprint bit
19	FP_330	0.0180	Morgan fingerprint bit
20	FP_305	0.0172	Morgan fingerprint bit

ข้อค้นพบที่สำคัญที่สุด

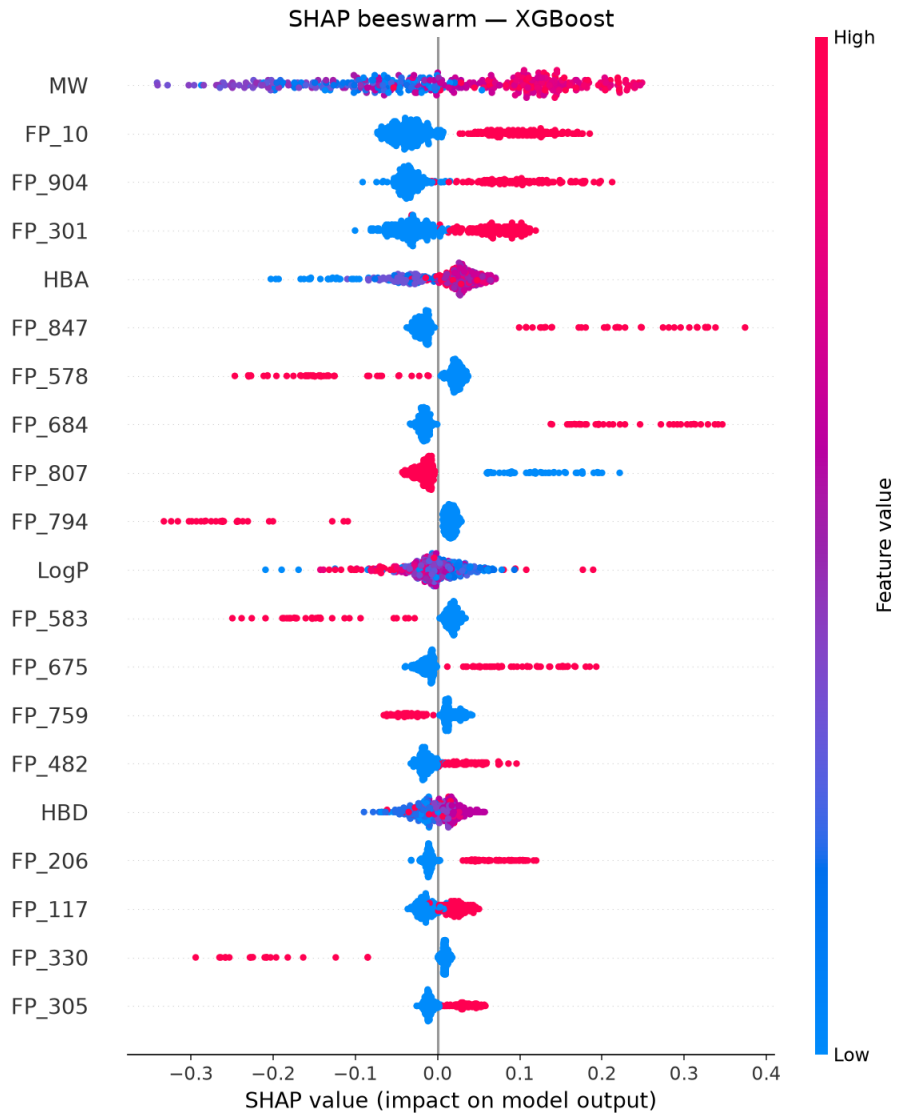
น้ำหนักโมเลกุลเป็นคุณลักษณะที่มีอิทธิพลสูงสุด โดยมีค่า Mean|SHAP| = 0.1165 ซึ่งสูงกว่าบิต Fingerprint ที่ดีที่สุดถึง 2.08 เท่า และ **Lipinski Descriptors ติดอันดับ 20 แรกครบทั้ง 4 ตัว**

ผลนี้ดูขัดแย้งกับผลการศึกษา Ablation ที่พบว่าการเพิ่ม Lipinski เข้าไปเพิ่มค่า R^2 เพียง 0.0112 คำอธิบายคือ Morgan Fingerprints เข้ารหัสข้อมูลเกี่ยวกับขนาดและองค์ประกอบของโมเลกุลไว้โดยอ้อมอยู่แล้ว เพราะโมเลกุลใหญ่ย่อมมีบิตถูกเซ็ตมากกว่า เมื่อตัด Lipinski ออก แบบจำลองจึงสามารถชดเชยด้วยการรวมสารสนเทศจากบิตหลายบิตแทน คุณลักษณะ Lipinski จึง **สำคัญแต่ซ้ำซ้อน (Important but Redundant)** ซึ่งเป็นสถานการณ์ที่พบได้ทั่วไปเมื่อวิเคราะห์

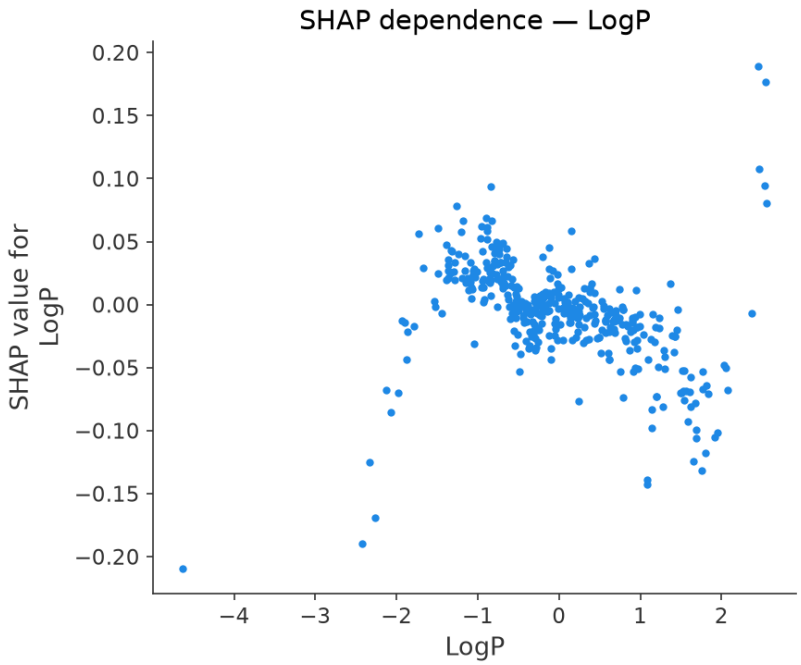
ความสำคัญของคุณลักษณะ



ภาพที่ 4.8 ค่าความสำคัญของคุณลักษณะ 20 อันดับแรกโดย Mean|SHAP|



ภาพที่ 4.9 SHAP Beeswarm Plot แสดงทิศทางอิทธิพลของแต่ละคุณลักษณะ



ภาพที่ 4.10 SHAP Dependence Plot ของค่า LogP

ตารางที่ 4.15 ตารางวิเคราะห์ SAR ของโครงสร้างย่อยที่สำคัญ

บิต	Mean |SHAP|	ทิศทาง	SHAP เมื่อ บิต=1	% ใน active	% ใน inactive	จำนวน โมเลกุล
FP_10	0.0561	เพิ่มฤทธิ์	$+0.1002$	**41.9**	**4.5**	696
FP_904	0.0557	เพิ่มฤทธิ์	$+0.1005$	33.6	19.7	634
FP_301	0.0484	เพิ่มฤทธิ์	$+0.0710$	**50.9**	**13.1**	908
FP_578	0.0364	ลดฤทธิ์	-0.1417	6.1	25.8	276
FP_807	0.0304	ลดฤทธิ์	-0.0173	84.4	95.5	1,904
FP_794	0.0303	ลดฤทธิ์	-0.2509	**2.0**	**19.7**	130

ผลการวิเคราะห์ SAR ให้ข้อมูลที่ตีความเชิงเคมีได้อย่างสอดคล้องกัน

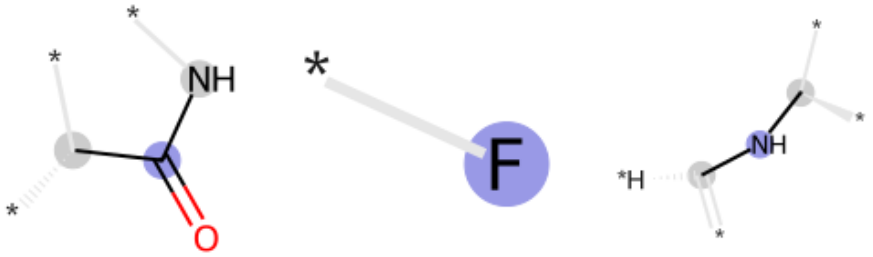
บิตที่เพิ่มฤทธิ์ บิต FP_301 ปรากฏในสารกลุ่ม active ถึงร้อยละ 50.9 แต่ปรากฏในกลุ่ม inactive เพียงร้อยละ 13.1 คิดเป็นอัตราส่วนความเข้มข้น 3.9 เท่า และบิต FP_10 มีอัตราส่วนสูงถึง 9.3 เท่า (ร้อยละ 41.9 เทียบกับ 4.5) โมเลกุลตัวอย่างที่มีบิต FP_10 และมีค่า SHAP สูงสุดคือสารที่มีโครงสร้างเปปไทด์คล้ายพร้อมหมู่แอลดีไฮด์ที่ปลาย ซึ่งเป็นหมู่ที่ทราบกันดีว่าสร้างพันธะโควาเลนต์แบบผันกลับได้กับซิสเตอีนที่ตำแหน่ง 145 ในช่องเร่งปฏิกิริยาของ M^{pro}

บิตที่ลดฤทธิ์ บิต FP_794 ปรากฏในกลุ่ม inactive ร้อยละ 19.7 แต่ปรากฏในกลุ่ม active เพียงร้อยละ 2.0 และมีค่า SHAP เฉลี่ยเมื่อบิตถูกเซ็ตติดลบมากที่สุดที่ -0.2509 โมเลกุลตัวอย่าง

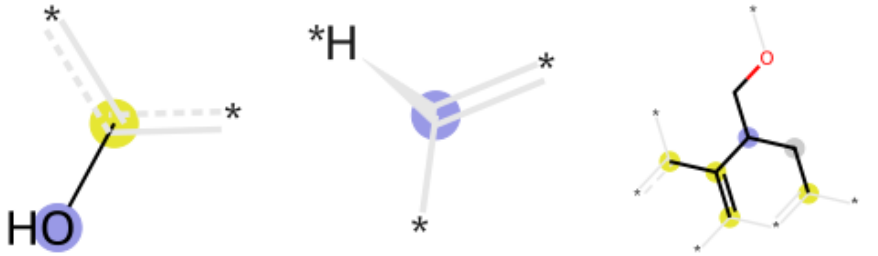
เป็นสารกลุ่มพอลิไซคลิกอะโรมาติกที่ไม่มีหมู่ฟังก์ชันสำหรับสร้างพันธะโควาเลนต์

ข้อสังเกตเชิงระเบียบวิธี

บิต FP_807 มีลักษณะพิเศษคือปรากฏในโมเลกุลถึง 1,904 ตัวจาก 2,198 ตัว (ร้อยละ 86.6) และปรากฏในทั้งกลุ่ม active (ร้อยละ 84.4) และ inactive (ร้อยละ 95.5) ในสัดส่วนใกล้เคียงกัน บิตนี้จึงเป็นโครงสร้างย่อยทั่วไปที่พบได้ในสารเกือบทุกตัว ค่า SHAP ที่ติดลบเล็กน้อยจึงไม่ควรตีความว่าโครงสร้างนี้ลดฤทธิ์อย่างมีความหมายทางเคมี แต่เป็นผลจากการที่แบบจำลองใช้บิตนี้เป็นค่าอ้างอิงพื้นฐานมากกว่า



(ก) บิต 10 — เพิ่มฤทธิ์ (ข) บิต 904 — เพิ่มฤทธิ์ (ค) บิต 301 — เพิ่มฤทธิ์



(ง) บิต 578 — ลดฤทธิ์ (จ) บิต 807 — ลดฤทธิ์ (ฉ) บิต 794 — ลดฤทธิ์

ภาพที่ 4.11 โครงสร้างย่อย 2 มิติของบิตสำคัญทั้ง 6 บิตที่ได้จากการจับคู่ย้อนกลับ

4.8 ผลการทดสอบข้ามชุดข้อมูล

ตารางที่ 4.16 ผลการทดสอบข้ามชุดข้อมูลกับ DDH COVID-19

ตัวชี้วัด	**ค่า**
จำนวนสาร (หลังตัดที่ซ้ำกับชุดฝึก 4 ตัว)	90
R^2	-1.7191
RMSE	1.3504
MAE	1.2031
Spearman ρ	0.5203
ค่าคลาดเคลื่อนเฉลี่ย (Bias)	$+1.1855$

ผลลบที่ต้องรายงานอย่างตรงไปตรงมา

ค่า R^2 ที่ติดลบหมายความว่าแบบจำลองทำนายชุด DDH ได้แย่กว่าการทายด้วยค่าเฉลี่ยของชุด DDH เอง และค่า Bias ที่ $+1.1855$ แสดงว่าแบบจำลองทำนายสูงเกินจริงอย่างเป็นระบบถึง 1.19 log unit หรือคิดเป็นการประเมินความแรงเกินจริงประมาณ 15 เท่า

ตารางที่ 4.17 ผลการวิเคราะห์ Applicability Domain

ชุดข้อมูล	**จำนวน**	**Tanimoto เฉลี่ย**	**มัธยฐาน**	**% < 0.4**
ChEMBL test (ในโดเมน)	550	0.7541	0.7972	**7.6**
DDH external	90	0.3340	0.2897	**84.4**
MultiTarget (นอกโดเมน)	1,331	0.2880	0.2738	**95.6**

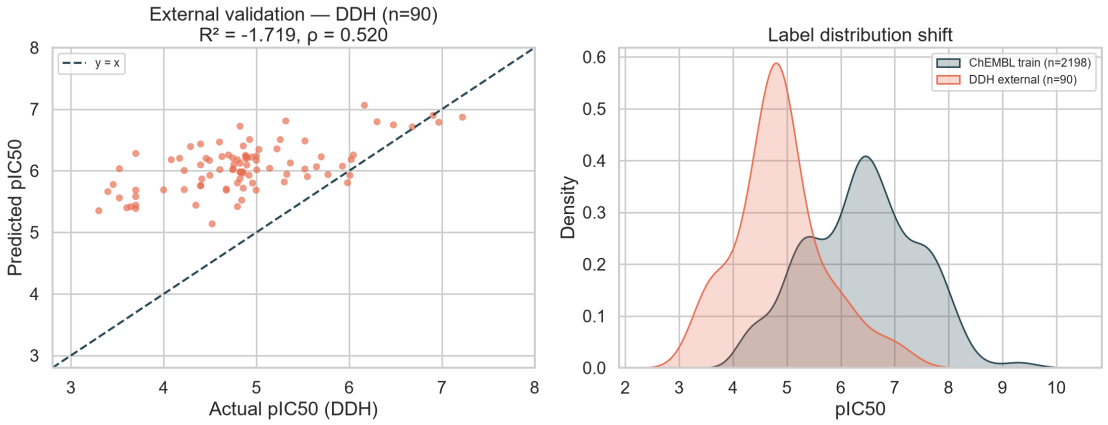
การวิเคราะห์ Applicability Domain อธิบายความล้มเหลวข้างต้นได้อย่างชัดเจน สารในชุด DDH ถึงร้อยละ 84.4 มีค่าความคล้ายคลึง Tanimoto สูงสุดต่อชุดฝึกต่ำกว่าเกณฑ์ 0.4 โดยมีค่ามัธยฐานเพียง 0.2897 ขณะที่ชุดทดสอบภายในมีเพียงร้อยละ 7.6 ที่อยู่นอกเกณฑ์ และมีค่ามัธยฐานสูงถึง 0.7972

กล่าวอีกนัยหนึ่ง ชุด DDH แทบเป็นสารคนละปริภูมิเคมีกับข้อมูลที่ใช้ฝึก โดยมีระดับความแตกต่างใกล้เคียงกับชุด MultiTarget ซึ่งเป็นสารที่ออกฤทธิ์ต่อเป้าหมายคนละชนิดโดยสิ้นเชิง (DRD2, HDAC1, BACE1)

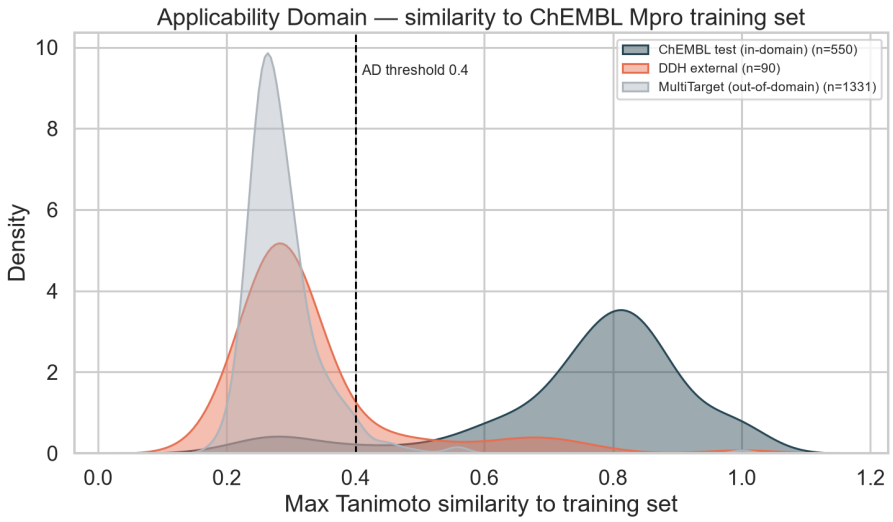
นอกจากนี้ยังมีปัจจัยเสริมคือการเลื่อนของการกระจายตัวแปรตาม (Label Distribution Shift) โดยชุด ChEMBL มี pIC_{50} เฉลี่ย 6.393 และประกอบด้วยสาร active เป็นส่วนใหญ่ ขณะที่ชุด DDH มีค่าเฉลี่ยเพียง 4.872 และเป็นสาร inactive ถึง 61 จาก 90 ตัว เมื่อประกอบกับจุดอ่อนของแบบจำลองที่ทำนายสาร inactive สูงเกินจริง จึงส่งผลให้ความคลาดเคลื่อนสะสมรุนแรงขึ้น

สิ่งที่ยังใช้ได้

ค่า Spearman ρ = 0.5203 บ่งชี้ว่าแบบจำลองยังคงจัดอันดับสารได้ในระดับปานกลาง แม้ค่าสัมบูรณ์จะคลาดเคลื่อนมาก ในทางปฏิบัติหมายความว่าแบบจำลองยังพอใช้เป็นเครื่องมือจัดลำดับความสำคัญเพื่อคัดกรองเบื้องต้นได้ แต่ไม่ควรใช้ค่า pIC_{50} ที่ทำนายได้เป็นตัวเลขสัมบูรณ์กับสารนอกโดเมน



ภาพที่ 4.12 ผลการทดสอบข้ามชุดข้อมูล (ซ้าย) และการเลื่อนของการกระจายตัวแปรตาม (ขวา)



ภาพที่ 4.13 การวิเคราะห์ Applicability Domain ด้วยค่าความคล้ายคลึง Tanimoto

ตารางที่ 4.18 ผลการทำนายสาร BLINDED จำนวน 10 ตัว

ลำดับสาร	pIC_{50} ที่ทำนาย	IC_{50} ที่ทำนาย (μM)
4	5.476	3.345
23	5.833	1.469
28	5.810	1.549
42	5.994	1.014
46	6.225	0.596
58	6.546	0.285
63	**6.990**	**0.102**
68	6.500	0.316
74	6.251	0.561
95	5.868	1.355

สารลำดับที่ 63 ได้รับการทำนายว่ามีฤทธิ์แรงที่สุด อย่างไรก็ตาม เนื่องจากสารกลุ่มนี้อยู่ในชุด DDH ซึ่งพบว่าอยู่นอก Applicability Domain เป็นส่วนใหญ่ ค่าทำนายเหล่านี้จึงควรถือเป็นเพียงการสาธิตการใช้งานระบบ และควรตีความในเชิงลำดับมากกว่าค่าสัมบูรณ์

บทที่ 5

สรุปผล อภิปรายผล และข้อเสนอแนะ

5.1 สรุปผลการดำเนินงาน

โครงงานนี้ได้พัฒนาแบบจำลองการเรียนรู้ของเครื่องสำหรับทำนายค่าฤทธิ์การยับยั้งเอนไซม์ SARS-CoV-2 Main Protease ในรูป pIC_{50} แบบ In Silico โดยดำเนินงานครบทั้ง 9 ระยะตามแผน สรุปผลได้ดังนี้

ด้านข้อมูล รวบรวมข้อมูลจาก ChEMBL เป้าหมาย CHEMBL4523582 จำนวน 4,867 รายการ กรอง assay เฉพาะที่วัด $3CL^{pro}$ เหลือ 2,889 รายการ (คัดออกร้อยละ 40.6 ซึ่งเป็น assay ของ nsp3, PLpro และ papain-like protease) ผ่านการทำความสะอาด 13 ขั้นตอน ได้ชุดข้อมูลมาตรฐาน **2,198 โมเลกุลที่ไม่ซ้ำกัน** ประกอบด้วยสาร active 1,453 ตัว intermediate 547 ตัว และ inactive 198 ตัว มีความหลากหลายเชิงโครงสร้างสูงโดยมี Murcko Scaffold ไม่ซ้ำ 976 แบบ

ด้านแบบจำลอง XGBoost ให้ประสิทธิภาพสูงสุดบนชุดทดสอบ โดยได้ R^2 = 0.7034, RMSE = 0.5487, MAE = 0.3918 และ Spearman ρ = 0.8415 ซึ่งเหนือกว่าแบบจำลองพื้นฐานอย่างชัดเจน ($R^2 = -0.0000$) การทำนายร้อยละ 93.6 มีความคลาดเคลื่อนไม่เกิน 1 log unit เมื่อประเมินด้วยการแบ่งข้อมูลตามโครงสร้างแกนกลาง ค่า R^2 ลดลงเหลือ 0.5127

ด้านการวิเคราะห์ SAR ระบุคุณลักษณะสำคัญได้ โดยน้ำหนักโมเลกุลมีอิทธิพลสูงสุด (Mean|SHAP| = 0.1165) และสามารถจับคู่ย้อนกลับเป็นภาพโครงสร้างย่อย 2 มิติได้ 6 บิต ซึ่งมีการกระจายตัวระหว่างกลุ่ม active และ inactive ที่แตกต่างกันอย่างชัดเจน

5.2 อภิปรายผลตามวัตถุประสงค์

ตารางที่ 5.1 สรุปการบรรลุวัตถุประสงค์

วัตถุประสงค์	สถานะ	หลักฐานสนับสนุน
1. พัฒนาและเปรียบเทียบแบบจำลอง ML ทำนาย pIC_{50}	บรรลุ	เปรียบเทียบครบ 4 แบบจำลอง บน 2 วิธีการแบ่งข้อมูล ได้ Test R^2 = 0.7034
2. สร้างกระบวนการ Hybrid Features ผ่าน Pipeline ที่ปลอด Leakage	บรรลุ	`src/pipelines.py` ร่วมกับการทดลอง Ablation E3/E4 และการวัดผล Leakage เชิงปริมาณ E5/E5b
3. วิเคราะห์ SAR ด้วย SHAP และภาพโครงสร้าง 2 มิติ	บรรลุ	ตาราง Top-20 Mean|SHAP|, Beeswarm Plot และภาพโครงสร้างย่อย 6 บิต

5.2.1 อภิปรายวัตถุประสงค์ที่ 1

แบบจำลองที่พัฒนาขึ้นบรรลุเกณฑ์ "ดี" ที่กำหนดไว้ล่วงหน้า (R^2 ในช่วง 0.60–0.75) ค่า RMSE = 0.5487 log unit หมายความว่าโดยเฉลี่ยแบบจำลองทำนายค่า IC_{50} คลาดเคลื่อนประมาณ 3.5 เท่า ซึ่งอยู่ในระดับที่ยอมรับได้สำหรับงานคัดกรองเบื้องต้น เนื่องจากความแปรปรวนของการทดลองในห้องปฏิบัติการเองระหว่างห้องปฏิบัติการต่างกันก็อยู่ในระดับใกล้เคียงกัน

ค่า Spearman ρ = 0.8415 ซึ่งสูงกว่าที่ค่า R^2 บ่งชี้ เป็นข้อค้นพบที่มีนัยสำคัญเชิงปฏิบัติ เพราะในงานคัดกรองยาสิ่งที่ต้องการมากที่สุดคือความสามารถ **จัดลำดับ** สารเพื่อเลือกไปทดสอบจริง ไม่ใช่ความแม่นยำของค่าสัมบูรณ์

ประเด็นที่น่าสังเกตคือ XGBoost ทำได้ต่ำที่สุดในระยะ Cross-Validation ก่อนปรับจูน (CV R^2 = 0.5803) แต่กลับดีที่สุดหลังปรับจูน (Test R^2 = 0.7034) แสดงว่าค่าเริ่มต้นของ XGBoost ไม่เหมาะกับข้อมูลชุดนี้ และการปรับจูนไฮเปอร์พารามิเตอร์มีความสำคัญมากกว่าการเลือกอัลกอริทึม

5.2.2 อภิปรายวัตถุประสงค์ที่ 2

การสร้าง Pipeline ที่ป้องกัน Data Leakage บรรลุผลตามวัตถุประสงค์ในเชิงระเบียบวิธี แต่ **ผลการวัดเชิงปริมาณไม่เป็นไปตามสมมติฐานตั้งต้น**

สมมติฐานเดิมคาดว่าการปรับสเกลก่อนแบ่งข้อมูลจะทำให้ผลสูงเกินจริงอย่างเห็นได้ชัด แต่ผลการทดลอง E5 พบส่วนต่างเพียง $+0.0001$ R^2 คำอธิบายคือสัดส่วนคุณลักษณะที่ต้องปรับสเกลมีเพียงร้อยละ 0.39 และขนาดชุดข้อมูลใหญ่เพียงพอ

อย่างไรก็ตาม เมื่อออกแบบการทดลองเพิ่มเติม E5b เพื่อตรวจสอบ Feature Selection Leakage ซึ่งเป็นรูปแบบที่ตรวจพบจริงในไฟล์ `xfinal.csv` ที่ได้รับมอบมา พบอคติบวก $+0.0116$ R^2 ซึ่งมากกว่ารูปแบบแรกถึง 116 เท่า

บทเรียนเชิงระเบียบวิธี

การใช้ Pipeline ยังคงเป็นแนวปฏิบัติที่ถูกต้องและควรทำเสมอ แต่ผู้วิจัยควรตระหนักว่าความรุนแรงของ Data Leakage ขึ้นอยู่กับ **สัดส่วนของคุณลักษณะที่ได้รับผลกระทบ** และ **ขนาดของชุดข้อมูล** การรั่วไหลจากการคัดเลือกคุณลักษณะเป็นภัยคุกคามที่ใหญ่กว่าการรั่วไหลจากการปรับสเกลอย่างมีนัยสำคัญ

สำหรับผลการศึกษา Ablation พบว่า Hybrid Features ให้ผลดีที่สุดจริง แต่ส่วนเพิ่มจาก Lipinski Descriptors มีเพียง $+0.0112$ R^2 ขณะที่การวิเคราะห์ SHAP กลับพบว่า Lipinski ติดอันดับ 20 แรกครบทั้ง 4 ตัว และ MW เป็นอันดับ 1 ผลสองอย่างนี้ไม่ขัดแย้งกัน แต่สะท้อนปรากฏการณ์ **คุณลักษณะสำคัญแต่ซ้ำซ้อน** เพราะ Morgan Fingerprints เข้ารหัสข้อมูลขนาดโมเลกุลไว้โดยอ้อมอยู่แล้ว

5.2.3 อภิปรายวัตถุประสงค์ที่ 3

การวิเคราะห์ SAR ให้ผลที่ตีความเชิงเคมีได้อย่างสอดคล้อง โดยเฉพาะบิต FP_10 ที่มีอัตราส่วนความเข้มข้นระหว่างกลุ่ม active ต่อ inactive สูงถึง 9.3 เท่า และโมเลกุลตัวอย่างมีหมู่แอลดีไฮด์ซึ่งเป็นหมู่ที่ทราบกันว่าสร้างพันธะกับซิสเตอีนในช่องเร่งปฏิกิริยาของ M^{pro} ได้

อย่างไรก็ตาม ต้องย้ำข้อจำกัดที่ประกาศไว้ตั้งแต่ต้นว่า ผลการวิเคราะห์ SHAP แสดง **ความสัมพันธ์เชิงสถิติ** ระหว่างชิ้นส่วนโมเลกุลกับค่าที่แบบจำลองทำนาย ไม่สามารถอ้างเป็น **กลไกการจับทางชีวภาพเชิงสาเหตุ** ในระดับ 3 มิติได้ ความสอดคล้องกับความรู้ทางเคมียาที่พบเป็นเพียงหลักฐานสนับสนุนความสมเหตุสมผล ไม่ใช่การพิสูจน์กลไก การยืนยันที่แท้จริงต้องอาศัย Molecular Docking, Molecular Dynamics และการทดสอบ In Vitro

กรณีบิต FP_807 เป็นตัวอย่างที่ดีของความจำเป็นในการตรวจสอบผล SHAP ด้วยสถิติเชิงพรรณนาประกอบ เนื่องจากบิตนี้ปรากฏในโมเลกุลถึงร้อยละ 86.6 ทั้งในกลุ่ม active และ inactive ค่า SHAP ที่ติดลบจึงไม่มีความหมายเชิงเคมีที่ตีความได้ หากรายงานเฉพาะอันดับ Mean|SHAP| โดยไม่ดูสัดส่วนการปรากฏ อาจนำไปสู่การตีความที่ผิดพลาด

5.3 ข้อค้นพบสำคัญที่นอกเหนือจากวัตถุประสงค์

5.3.1 ความล้มเหลวของการทดสอบข้ามชุดข้อมูล

ข้อค้นพบที่มีคุณค่าที่สุดของโครงงานนี้อาจเป็นผลลบ กล่าวคือ แบบจำลองที่ได้ค่า R^2 = 0.7034 บนชุดทดสอบภายใน กลับได้ R^2 = -1.72 เมื่อทดสอบกับสาร COVID-19 จากแหล่งอิสระ 90 ตัว

การวิเคราะห์ Applicability Domain อธิบายสาเหตุได้อย่างชัดเจนว่า ร้อยละ 84.4 ของสารในชุดทดสอบข้ามแหล่งมีค่าความคล้ายคลึง Tanimoto ต่อชุดฝึกต่ำกว่า 0.4 ซึ่งใกล้เคียงกับชุดสารที่ออกฤทธิ์ต่อเป้าหมายคนละชนิดโดยสิ้นเชิง

นัยเชิงวิชาการ

ผลนี้เป็นหลักฐานเชิงประจักษ์ที่สนับสนุนข้อวิจารณ์ที่มีต่องานวิจัย QSAR จำนวนมากที่รายงานเฉพาะค่า R^2 บนชุดทดสอบภายใน โดยไม่ประเมิน Applicability Domain หรือทดสอบข้ามแหล่งข้อมูล ค่า R^2 ที่สูงในการแบ่งข้อมูลแบบสุ่มไม่ได้รับประกันความสามารถทำนายในทางปฏิบัติเลย

5.3.2 ผลกระทบของความไม่สมดุลของข้อมูล

การวิเคราะห์ค่าคลาดเคลื่อนแยกตามกลุ่มฤทธิ์เผยให้เห็นว่า แบบจำลองทำนายสาร inactive สูงเกินจริงอย่างเป็นระบบเฉลี่ย 0.72 log unit ซึ่งเป็นผลจากอัตราส่วนสาร active ต่อ inactive ในชุดฝึกที่ 7.3 ต่อ 1

ข้อค้นพบนี้เชื่อมโยงโดยตรงกับความล้มเหลวในหัวข้อก่อนหน้า เพราะชุด DDH ประกอบด้วยสาร inactive ถึง 61 จาก 90 ตัว จึงตกอยู่ในสถานการณ์ที่แบบจำลองอ่อนแอที่สุดพอดี ความไม่สมดุลของข้อมูลจึงไม่ได้ส่งผลเฉพาะในงานจำแนกประเภทเท่านั้น แต่ส่งผลต่องานถดถอยด้วยเมื่อการกระจายของตัวแปรตามไม่สมมาตร

5.3.3 ข้อจำกัดของ Morgan Fingerprints กับสเตอริโอเคมี

การวิเคราะห์ Activity Cliff พบคู่โมเลกุลที่มีความคล้ายคลึงเกิน 0.85 จำนวน 635 คู่ ในจำนวนนี้มี 23 คู่ (ร้อยละ 3.62) ที่มีค่า pIC_{50} ต่างกันเกิน 1.5 log unit

เมื่อตรวจสอบคู่ที่รุนแรงที่สุดพบว่าเป็น **สเตอริโอไอโซเมอร์** ตัวอย่างเช่น สาร CHEMBL5412571 มี pIC_{50} = 8.52 ขณะที่ CHEMBL5197241 มี pIC_{50} = 6.33 ทั้งสองมีสูตรโครงสร้างเชิงเส้นเหมือนกันทุกประการ ต่างกันเพียงการจัดเรียงสเตอริโอที่ศูนย์กลางไครัลสองตำแหน่ง แต่มีฤทธิ์ต่างกันถึง 2.19 log unit หรือประมาณ 155 เท่า

ค่าความคล้ายคลึง Tanimoto ระหว่างสองโมเลกุลนี้เท่ากับ **1.000 พอดี** เนื่องจาก Morgan Fingerprints ที่ตั้งค่าตามปกติไม่บันทึกข้อมูลสเตอริโอเคมี แบบจำลองจึงได้รับเวกเตอร์คุณลักษณะที่เหมือนกันทุกประการสำหรับโมเลกุลสองตัวที่มีฤทธิ์ต่างกันมหาศาล และไม่มีทางทำนายทั้งคู่ให้ถูกต้องพร้อมกันได้

ข้อค้นพบนี้มีความสำคัญมากในบริบทของสารยับยั้ง M^{pro} เพราะสารกลุ่มนี้จำนวนมากมีลักษณะคล้ายเปปไทด์ซึ่งมีศูนย์กลางไครัลหลายตำแหน่ง และการจับกับโปรตีนขึ้นอยู่กับรูปทรงสามมิติอย่างมาก

5.4 ข้อจำกัดของการศึกษา

1. **เป็นการศึกษา In Silico เท่านั้น** ไม่มีการยืนยันผลในห้องปฏิบัติการ สารที่แบบจำลองทำนายว่ามีฤทธิ์แรงยังไม่ได้รับการทดสอบจริง

2. **SHAP แสดงความสัมพันธ์เชิงสถิติ ไม่ใช่กลไกเชิงสาเหตุ** โครงสร้างย่อยที่ระบุได้เป็นเพียงรูปแบบทางสถิติที่แบบจำลองเรียนรู้ ไม่ใช่การพิสูจน์ว่าโครงสร้างนั้นทำหน้าที่จับกับเอนไซม์จริง

3. **ข้อมูลมาจากหลายห้องปฏิบัติการและหลายโปรโตคอล** แม้จะกรอง assay เฉพาะ $3CL^{pro}$ แล้ว แต่วิธีการวัด ความเข้มข้นของเอนไซม์ และชนิดสับสเตรตที่ต่างกันยังเป็นแหล่งความแปรปรวนในตัวแปรตาม

4. **คุณลักษณะไม่ครอบคลุมสเตอริโอเคมี** ซึ่งเป็นข้อจำกัดเชิงหลักการที่ส่งผลต่อความสามารถทำนายสารกลุ่มเปปไทด์คล้าย

5. **ความสามารถทำนายจำกัดอยู่ในปริภูมิเคมีของชุดฝึก** ตามที่พิสูจน์แล้วด้วยการทดสอบข้ามชุดข้อมูล

6. **ไม่ครอบคลุม Molecular Docking และ Molecular Dynamics** ตามขอบเขตที่ประกาศไว้

5.5 ข้อเสนอแนะ

5.5.1 ข้อเสนอแนะสำหรับการนำผลไปใช้

1. **ใช้แบบจำลองเป็นเครื่องมือจัดลำดับความสำคัญ ไม่ใช่เครื่องมือวัดค่าสัมบูรณ์** เนื่องจากค่า Spearman ρ สูงกว่าที่ค่า R^2 บ่งชี้ การใช้แบบจำลองเพื่อเรียงลำดับสารก่อนนำไปทดสอบจริงจะให้ประโยชน์สูงสุด

2. **ตรวจสอบ Applicability Domain ก่อนใช้ทุกครั้ง** ควรคำนวณค่า Tanimoto สูงสุดต่อชุดฝึกก่อนเชื่อผลทำนาย หากต่ำกว่า 0.4 ควรถือว่าผลทำนายไม่น่าเชื่อถือ

3. **อ้างอิงค่า $R^2 = 0.5127$ จาก Scaffold Split** เมื่อสื่อสารความสามารถของแบบจำลองในการทำนายสารที่มีโครงสร้างแกนกลางใหม่

5.5.2 ข้อเสนอแนะสำหรับการพัฒนาต่อยอด

1. **เปิดใช้งานสเตอริโอเคมีในการสกัด Fingerprints** โดยตั้งค่า `includeChirality=True` ซึ่งจะช่วยแก้ปัญหาสเตอริโอไอโซเมอร์ได้โดยตรง คาดว่าจะเป็นการปรับปรุงที่ให้ผลตอบแทนสูงที่สุดเมื่อเทียบกับความพยายามที่ใช้

2. **แก้ปัญหาความไม่สมดุลของข้อมูล** ด้วยการเพิ่มน้ำหนักตัวอย่างสาร inactive ในฟังก์ชันสูญเสีย หรือรวบรวมข้อมูลสาร inactive เพิ่มเติมจากฐานข้อมูล PubChem BioAssay

3. **ทดลองใช้คุณลักษณะเพิ่มเติม** เช่น RDKit Descriptors ชุดเต็ม, MACCS Keys หรือ Pharmacophore Fingerprints เพื่อเพิ่มมิติของสารสนเทศ

4. **ทดลองใช้แบบจำลองที่เรียนรู้การแทนโครงสร้างเอง** เช่น Graph Neural Networks (GNN) ซึ่งรับโครงสร้างโมเลกุลเป็นกราฟโดยตรง และสามารถเข้ารหัสสเตอริโอเคมีได้

5. **สร้างแบบจำลองประมาณความไม่แน่นอน** เช่น Conformal Prediction หรือ Ensemble Variance เพื่อให้แบบจำลองสามารถบอกได้ว่าตัวเองไม่มั่นใจเมื่อใด ซึ่งจะช่วยลดปัญหาการทำนายสารนอกโดเมน

6. **พัฒนาเว็บแอปพลิเคชันคัดกรองตัวยา** โดยรับ SMILES เป็นข้อมูลนำเข้า แล้วแสดงค่า pIC_{50} ที่ทำนาย พร้อมค่าความคล้ายคลึงต่อชุดฝึกเป็นตัวบ่งชี้ความน่าเชื่อถือ และภาพโครงสร้างย่อยที่มีอิทธิพลต่อการทำนาย

5.5.3 ข้อเสนอแนะเชิงระเบียบวิธีสำหรับงาน QSAR

1. **รายงานผลทั้ง Random Split และ Scaffold Split ควบคู่กันเสมอ** เพื่อให้ผู้อ่านเห็นภาพความสามารถทำนายที่แท้จริง

2. **ประเมินและรายงาน Applicability Domain เป็นส่วนหนึ่งของผลลัพธ์มาตรฐาน** ไม่ใช่การวิเคราะห์เสริม

3. **ตรวจสอบการซ้อนทับระหว่างชุดฝึกกับชุดทดสอบข้ามแหล่งด้วย InChIKey เสมอ** ในโครงงานนี้พบสารซ้ำ 4 ตัวซึ่งหากไม่ตัดออกจะทำให้ผลการทดสอบข้ามชุดข้อมูลไม่ถูกต้อง

4. **วิเคราะห์ค่าคลาดเคลื่อนแยกตามกลุ่มย่อย** ไม่ใช่รายงานเฉพาะค่ารวม เพราะค่ารวมอาจซ่อนจุดอ่อนเชิงระบบไว้ ดังกรณีสาร inactive ในโครงงานนี้

5. **ตรวจสอบผล SHAP ด้วยสถิติเชิงพรรณนาประกอบ** เช่น สัดส่วนการปรากฏของบิตในแต่ละกลุ่ม เพื่อป้องกันการตีความผิดพลาดดังกรณีบิต FP_807

บรรณานุกรม

[1] Jin, Z., Du, X., Xu, Y., Deng, Y., Liu, M., Zhao, Y., ... & Yang, H. (2020). Structure of M^{pro} from SARS-CoV-2 and discovery of its inhibitors. *Nature*, 582(7811), 289–293. https://doi.org/10.1038/s41586-020-2223-y

[2] Gaulton, A., Hersey, A., Nowotka, M., Bento, A. P., Chambers, J., Mendez, D., ... & Overington, J. P. (2017). The ChEMBL database in 2017. *Nucleic Acids Research*, 45(D1), D945–D954. https://doi.org/10.1093/nar/gkw1074

[3] Rogers, D., & Hahn, M. (2010). Extended-connectivity fingerprints. *Journal of Chemical Information and Modeling*, 50(5), 742–754. https://doi.org/10.1021/ci100050t

[4] Lipinski, C. A., Lombardo, F., Dominy, B. W., & Feeney, P. J. (2001). Experimental and computational approaches to estimate solubility and permeability in drug discovery and development settings. *Advanced Drug Delivery Reviews*, 46(1-3), 3–26. https://doi.org/10.1016/S0169-409X(00)00129-0

[5] Nantasenamat, C., Isarankura-Na-Ayudhya, C., Naenna, T., & Prachayasittikul, V. (2010). A practical overview of quantitative structure-activity relationship. *EXCLI Journal*, 9, 74–93. https://www.ncbi.nlm.nih.gov/pmc/articles/PMC5084994/

[6] Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32. https://doi.org/10.1023/A:1010933404324

[7] Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794). https://doi.org/10.1145/2939672.2939785

[8] Rodríguez-Pérez, R., & Bajorath, J. (2020). Interpretation of machine learning predictions using Shapley values: Application to compound activity and property prediction. *Molecular Informatics*, 39(1-2), 1900131. https://doi.org/10.1002/minf.201900131

[9] Bemis, G. W., & Murcko, M. A. (1996). The properties of known drugs. 1.

Molecular frameworks. *Journal of Medicinal Chemistry*, 39(15), 2887–2893. https://doi.org/10.1021/jm9602928

[10] Sheridan, R. P. (2013). Time-split cross-validation as a method for estimating the goodness of prospective prediction. *Journal of Chemical Information and Modeling*, 53(4), 783–790. https://doi.org/10.1021/ci400084k

[11] Lundberg, S. M., & Lee, S. I. (2017). A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems 30* (pp. 4765–4774).

[12] Maggiora, G. M. (2006). On outliers and activity cliffs — Why QSAR often disappoints. *Journal of Chemical Information and Modeling*, 46(4), 1535. https://doi.org/10.1021/ci060117s

[13] Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., … & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

[14] Landrum, G. (2024). *RDKit: Open-source cheminformatics*. https://www.rdkit.org

ภาคผนวก A

โครงสร้างไฟล์และโค้ดโปรแกรม

A.1 โครงสร้างโปรเจกต์

```
SilicoBioactivityPredict/
├── .venv/                          project virtual environment
├── Data_set/                       original raw data (read-only)
├── Docs/
│   ├── Machine Learning ....pdf    project proposal
│   └── Project_Plan.md             execution plan
├── data/
│   ├── raw/                        raw ChEMBL API output
│   ├── interim/                    after assay filtering
│   └── processed/
│       ├── clean_bioactivity_master.csv    2,198 molecules
│       ├── features_hybrid.parquet         1,028 features
│       ├── bitinfo.pkl                     Morgan bit info
│       ├── predictions_test.csv
│       └── predictions_external_ddh.csv
├── src/                            source code, 11 files
│   ├── config.py                   global constants
│   ├── acquire.py                  Phase 1
│   ├── clean.py                    Phase 2
│   ├── features.py                 Phase 3
│   ├── eda.py                      Phase 4
│   ├── pipelines.py                Pipeline + Scaffold Split
│   ├── model_cv.py                 Phase 5
│   ├── tune_eval.py                Phase 6
│   ├── explain.py                  Phase 7
│   ├── external_validation.py      Phase 8
│   └── make_report.py              automated report builder
├── models/best_model_xgboost_20260908.joblib
├── reports/
│   ├── figures/                    18 figures
│   ├── tables/                     10 result tables
│   ├── latex/                      LaTeX source of this report
│   └── final_report.md
├── requirements.txt
└── README.md
```

A.2 ลำดับการรันโปรแกรม

```
cd src && ../.venv/Scripts/python.exe acquire.py
cd src && ../.venv/Scripts/python.exe clean.py
```

```
cd src && ../.venv/Scripts/python.exe features.py
cd src && ../.venv/Scripts/python.exe eda.py
cd src && ../.venv/Scripts/python.exe model_cv.py
cd src && ../.venv/Scripts/python.exe tune_eval.py
cd src && ../.venv/Scripts/python.exe explain.py
cd src && ../.venv/Scripts/python.exe external_validation.py
cd src && ../.venv/Scripts/python.exe make_report.py
```

A.3 โค้ดสำคัญ: Pipeline ป้องกัน Data Leakage

```
from sklearn.pipeline import Pipeline
from sklearn.compose import ColumnTransformer
from sklearn.preprocessing import StandardScaler

def make_pipe(estimator, fp_cols=FP_COLS, desc_cols=DESC_COLS):
    transformers = []
    if fp_cols:
        transformers.append(("fp", "passthrough", list(fp_cols)))
    if desc_cols:
        transformers.append(("desc", StandardScaler(), list(desc_cols)))
    prep = ColumnTransformer(transformers, remainder="drop")
    return Pipeline([("prep", prep), ("model", estimator)])
```

A.4 โค้ดสำคัญ: Scaffold Split

```
from collections import defaultdict
from rdkit.Chem.Scaffolds import MurckoScaffold

def scaffold_split(smiles_list, test_frac=0.25):
    buckets = defaultdict(list)
    for i, s in enumerate(smiles_list):
        sc = MurckoScaffold.MurckoScaffoldSmiles(
            smiles=s, includeChirality=False)
        buckets[sc].append(i)
    groups = sorted(buckets.values(), key=len, reverse=True)
    n_train = len(smiles_list) - int(len(smiles_list) * test_frac)
    train, test = [], []
    for g in groups:
        (train if len(train) + len(g) <= n_train else test).extend(g)
    return np.array(train), np.array(test)
```

A.5 โค้ดสำคัญ: การสกัดคุณลักษณะแบบผสม

```
from rdkit import Chem
from rdkit.Chem import Descriptors, Lipinski, rdFingerprintGenerator

gen = rdFingerprintGenerator.GetMorganGenerator(radius=2, fpSize=1024)
```

```
def featurize(smiles):
    mol = Chem.MolFromSmiles(smiles)
    ao = rdFingerprintGenerator.AdditionalOutput()
    ao.AllocateBitInfoMap()
    fp = gen.GetFingerprintAsNumPy(mol, additionalOutput=ao)
    desc = [Descriptors.MolWt(mol), Descriptors.MolLogP(mol),
            Lipinski.NumHDonors(mol), Lipinski.NumHAcceptors(mol)]
    return fp, desc, ao.GetBitInfoMap()
```

ภาคผนวก B

รายการไฟล์ผลลัพธ์

B.1 รายการภาพประกอบ

ตารางที่ B.1 รายการภาพประกอบผลการดำเนินงาน

ไฟล์	เนื้อหา
`fig01_pic50_distribution.png`	การแจกแจงความถี่ของค่า pIC_{50}
`fig02_chemical_space_mw_logp.png`	ปริภูมิเคมี MW เทียบ LogP แยกตามกลุ่มฤทธิ์
`fig02b_lipinski_by_class.png`	Box plot ของ Lipinski Descriptors ตามกลุ่มฤทธิ์
`fig02c_chemspace_3sets.png`	เปรียบเทียบปริภูมิเคมีของชุดข้อมูลสามชุด
`fig03_model_comparison.png`	เปรียบเทียบประสิทธิภาพ CV เทียบชุดทดสอบ
`fig04_residual_plot.png`	กราฟค่าทำนายเทียบค่าจริงและกราฟค่าคลาดเคลื่อน
`fig04b_residual_hist.png`	การแจกแจงค่าคลาดเคลื่อน
`fig05_shap_bar_top20.png`	ค่าความสำคัญของคุณลักษณะ 20 อันดับแรก
`fig06_shap_beeswarm.png`	SHAP Beeswarm Plot
`fig06b_shap_dependence_logp.png`	SHAP Dependence Plot ของ LogP
`fig07_bit_10_substructure.png`	โครงสร้างย่อยของบิต 10 (เพิ่มฤทธิ์)
`fig07_bit_904_substructure.png`	โครงสร้างย่อยของบิต 904 (เพิ่มฤทธิ์)
`fig07_bit_301_substructure.png`	โครงสร้างย่อยของบิต 301 (เพิ่มฤทธิ์)
`fig07_bit_578_substructure.png`	โครงสร้างย่อยของบิต 578 (ลดฤทธิ์)
`fig07_bit_807_substructure.png`	โครงสร้างย่อยของบิต 807 (ลดฤทธิ์)
`fig07_bit_794_substructure.png`	โครงสร้างย่อยของบิต 794 (ลดฤทธิ์)
`fig08_external_validation.png`	ผลการทดสอบข้ามชุดข้อมูล
`fig09_applicability_domain.png`	การวิเคราะห์ Applicability Domain

B.2 รายการตารางผลลัพธ์ดิบ

ตารางที่ B.2 รายการไฟล์ตารางผลลัพธ์

ไฟล์	เนื้อหา
`tbl01_dataset_summary.csv`	สรุปคุณลักษณะชุดข้อมูล
`tbl01b_lipinski_mannwhitney.csv`	ผลทดสอบ Mann-Whitney U
`tbl01c_top_scaffolds.csv`	Murcko Scaffold 10 อันดับแรก
`tbl02_cv_results.csv`	ผล Cross-Validation ทุกการทดลอง
`tbl03_test_results.csv`	ผลการประเมินบนชุดทดสอบ
`tbl04_shap_importance_top50.csv`	ค่าความสำคัญคุณลักษณะ 50 อันดับแรก
`tbl05_sar_bits.csv`	ตารางวิเคราะห์ SAR
`tbl06_applicability_domain.csv`	ผลวิเคราะห์ Applicability Domain
`tbl07_blinded_predictions.csv`	ผลทำนายสาร BLINDED
`tbl08_external_metrics.csv`	ตัวชี้วัดการทดสอบข้ามชุดข้อมูล